



Selección de Características

(CAPÍTULO 3 – PR03A)

Domingo Mery 


Ciencia de la Computación
Universidad Católica – Chile
<http://domingomery.ing.uc.cl>

	PERÍMETRO	AREA	ROJO	VERDE
Mandarina-01	350	9780	0.91	0.78
Mandarina-02	376	11230	0.85	0.62
Mandarina-03	424	14320	0.60	0.82
:				
Mandarina-50	489	15320	0.89	0.76
Naranja-01	473	17820	0.76	0.56
Naranja-02	408	13240	0.78	0.91
Naranja-03	439	15345	0.62	0.85
:				
Naranja-50	479	18290	0.56	0.76

5 razones para seleccionar características

1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
3. Para simplificar la fase de pruebas
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad

Ejemplo: Clasificación de monedas



5 razones para seleccionar características

1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
3. Para simplificar la fase de pruebas
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad

I. Para evitar características no discriminatorias – ~~Promedio de valores de gris~~



5 razones para seleccionar características

1. Para evitar características no discriminatorias
- 2. Para evitar características correlacionadas**
3. Para simplificar la fase de pruebas
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad

2. Para evitar características correlacionadas – Extraer Área y Diámetro ?



2. Para evitar características correlacionadas – Extraer Área ○ Diámetro (NO AMBAS)



5 razones para seleccionar características

1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
- 3. Para simplificar la fase de pruebas**
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad


3. Para simplificar la fase de pruebas – Área vs. ~~Hu+Flusser~~



5 razones para seleccionar características

1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
3. Para simplificar la fase de pruebas
- 4. Para evitar correlaciones falsas**
5. Para evitar la maldición de la dimensionalidad

4. Para evitar correlaciones falsas – Ubicación (centro de masa en dirección y)



5 razones para seleccionar características


1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
3. Para simplificar la fase de pruebas
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad

Maldición de la dimensionalidad – ID

○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○ ○


(20 puntos en ID)

Maldición de la dimensionalidad – 2D



Maldición de la adimensionalidad – 3D

Cuando la dimensionalidad aumenta, el volumen del espacio aumenta tan rápido que los datos disponibles se vuelven escasos. Esta escasez es problemática para cualquier método que requiera significación estadística.



(20 puntos en 3D)

5 razones para seleccionar características

1. Para evitar características no discriminatorias
2. Para evitar características correlacionadas
3. Para simplificar la fase de pruebas
4. Para evitar correlaciones falsas
5. Para evitar la maldición de la dimensionalidad



Extracción de Características

¿Cuáles sirven?
 ¿Son todas buenas?
 ¿Hay redundancia?
 ¿Son 'correctas'?

	PERÍMETRO	AREA	ROJO	VERDE
Mandarina-01	350	9780	0.91	0.78
Mandarina-02	376	11230	0.85	0.62
Mandarina-03	424	14320	0.60	0.82
:				
Mandarina-50	439	15320	0.89	0.76
Naranja-01	473	17820	0.76	0.56
Naranja-02	408	13240	0.78	0.91
Naranja-03	439	15345	0.62	0.85
:				
Naranja-50	479	18290	0.56	0.76



Extracción de Características

Analicemos una característica...

DOS CLASES

ω_0

ω_1


Mandarina-01
Mandarina-02
Mandarina-03
:
Mandarina-50
Naranja-01
Naranja-02
Naranja-03
:
Naranja-50

x

UNA CARACTERÍSTICA


9780
11230
14320
15320
17820
13240
15345
18290

Distribución de Frecuencias





x
9780
11230
14320
15320
17820
13240
15345
18290



Distribución de Frecuencias



Distribución de Frecuencias



Distribución de Frecuencias





Ejercicio: Selección de Características

I) Entre la a) y la b), cuál es la mejor?

	PERÍMETRO	AREA	ROJO	VERDE
Mandarina-01	350	9780	0.91	0.78
Mandarina-02	376	11230	0.85	0.62
Mandarina-03	424	14320	0.60	0.82
:				
Mandarina-50	439	15320	0.89	0.76
Naranja-01	473	17820	0.76	0.56
Naranja-02	408	13240	0.78	0.91
Naranja-03	439	15345	0.62	0.85
:				
Naranja-50	479	18290	0.56	0.76

a)

b)






Ejercicio: Selección de Características

1) Entre la a) y la b), cuál es la mejor?

2) Entre la c) y la d) cuál es mejor?





	PERÍMETRO	AREA	ROJO	VERDE
Mandarina-01	350	9780	0.91	0.78
Mandarina-02	376	11230	0.85	0.62
Mandarina-03	424	14320	0.60	0.82
:				
Mandarina-50	439	15320	0.89	0.76
Naranja-01	473	17820	0.76	0.56
Naranja-02	408	13240	0.78	0.91
Naranja-03	439	15345	0.62	0.85
:				
Naranja-50	479	18290	0.56	0.76
	a)	b)	c)	d)



Ejercicio: Selección de Características

- 1) Entre la a) y la b), cuál es la mejor?
- 2) Entre la c) y la d) cuál es mejor?
- 3) Y cuál es la mejor de todas?

	PERÍMETRO	AREA	ROJO	VERDE
Mandarina-01	350	9780	0.91	0.78
Mandarina-02	376	11230	0.85	0.62
Mandarina-03	424	14320	0.60	0.82
:				
Mandarina-50	439	15320	0.89	0.76
Naranja-01	473	17820	0.76	0.56
Naranja-02	408	13240	0.78	0.91
Naranja-03	439	15345	0.62	0.85
:				
Naranja-50	479	18290	0.56	0.76
	a)	b)	c)	d)







Ejercicio: Selección de Características

1) Entre la a) y la b), cuál es la mejor?

2) Entre la c) y la d) cuál es mejor?

3) Y cuál es la mejor de todas?

4) Cómo medir la separabilidad?



Ejercicio: Selección de Características


1) Entre la a) y la b), cuál es la mejor?

2) Entre la c) y la d) cuál es mejor?


3) Y cuál es la mejor de todas?

4) Cómo medir la separabilidad?


(qué nota le ponemos, y cómo calcular esta nota de manera objetiva?)




$$J = 7.0$$




$$J = 5.6$$




$$J = 4.1$$




$$J = 2.7$$




MEJOR QUE




MEJOR QUE




IDEA: $|\mu_1 - \mu_2|^2$ maximizar!




MEJOR QUE




MEJOR QUE




Medir la separación de las distribuciones,
entre mayor sea la distancia entre las medias, mejor es la separación.




MEJOR QUE




MEJOR QUE






MEJOR QUE




MEJOR QUE




Medir la dispersión de las distribuciones,
entre más angostas las campanas mejor es la separación.


IDEA GENERAL: $J = \frac{|\mu_1 - \mu_2|^2}{\sigma_1^2 + \sigma_2^2} \rightarrow \max$




MEJOR QUE




MEJOR QUE




Medir la separación de las distribuciones,
entre mayor sea la distancia entre las medias, mejor es la separación.



MEJOR QUE






MEJOR QUE





Medir la dispersión de las distribuciones,
entre más angostas las campanas mejor es la separación.

$$J = \frac{|\mu_1 - \mu_2|^2}{\sigma_1^2 + \sigma_2^2} \rightarrow \max$$



Con **una sola característica** es sencillo:
hay que medir medias y varianzas
y calcular J,
pero ¿qué pasa con **dos características**?





Malo




Bueno



Muy bueno






Con más características:

1) Hay que maximizar las distancias entre los centros de cada nube


Aquí: Una nube es el conjunto de puntos que pertenece a una clase



Con más características:

- 1) Hay que maximizar las distancias entre los centros de cada nube
- 2) Hay que minimizar la dispersión de cada nube

Aquí: Una nube es el conjunto de puntos que pertenece a una clase



Cómo escoger las mejores características? Se escogen aquellas que:

- 1) maximicen las distancias entre los centros de cada nube, y
- 2) minimicen la dispersión de cada nube

¿Cómo calcular J en términos generales para más características y más clases?

RECORDAR:


La variable J es un escalar que mide la separabilidad entre las clases (dado un conjunto de características)


×	class 1
+	class 2
▽	class 3

$$k = 1 \cdots 3$$

Ejemplo: 3 clases y 2 características

$$(z_1, z_2)$$






Centro de Masa
de cada clase

● $\bar{z}_k$

$k = 1 \dots 3$




Centro de Masa
de cada clase

● $\bar{z}_k$

$k = 1 \dots 3$

Centro de
Masa
de todas las
muestras

★ $\bar{z}$



Centro de Masa
de cada clase

● $\bar{z}_k$

$k = 1 \dots 3$

Centro de
Masa
de todas las
muestras

★ $\bar{z}$


Probabilidad a
priori de que
ocurra clase k

p_k

Matriz de Covarianza

(recordatorio)

$$\mathbf{C} = \frac{1}{N-1} \sum_{j=1}^N \underbrace{(\mathbf{z}_j - \bar{\mathbf{z}})}_{\text{feature space}} (\mathbf{z}_j - \bar{\mathbf{z}})^T$$



N número de muestras

centro de masa

$$\bar{\mathbf{z}} = \frac{1}{N} \sum_{j=1}^N \mathbf{z}_j$$


muestra j

$$\mathbf{z}_j = (z_{1j}, z_{2j})^T$$

$j = 1 \dots N$


Matriz de Covarianza

(ejemplos)




$C =$

0.9735	0.0041
0.0041	1.0105



$C =$


1.1465	1.0891
1.0891	1.1604



$C =$

0.6013	0.9290
0.9290	1.6678

Definiciones



Centro de Masa
de cada clase

● $\bar{z}_k$

$k = 1 \dots 3$

Centro de
Masa
de todas las
muestras


★ $\bar{z}$

Probabilidad a
priori de que
ocurra clase k

p_k

Covarianza Inter-Clase (between class covariance)

$$\mathbf{C}_b = \sum_k p_k (\bar{\mathbf{z}}_k - \bar{\mathbf{z}})(\bar{\mathbf{z}}_k - \bar{\mathbf{z}})^T$$



Covarianza Intra-Clase (within-class covariance)


$$\mathbf{C}_w = \sum_{k=1}^K p_k \mathbf{C}_k,$$

Promedio ponderado de las Covarianzas de la cada clase

$$\mathbf{C}_k = \frac{1}{N_k - 1} \sum_{j=1}^{N_k} (\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)(\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)^T$$

Covarianza de la clase k

N_k muestras de la clase k



Covarianza Intra-Clase (within-class covariance)


$$\mathbf{C}_w = \sum_{k=1}^K p_k \mathbf{C}_k,$$

Promedio ponderado de las Covarianzas de la cada clase

$$\mathbf{C}_k = \frac{1}{N_k - 1} \sum_{j=1}^{N_k} (\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)(\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)^T$$

Covarianza de la clase k

N_k muestras de la clase k



Covarianza Intra-Clase (within-class covariance)


$$\mathbf{C}_w = \sum_{k=1}^K p_k \mathbf{C}_k,$$

Promedio ponderado de las Covarianzas de la cada clase

$$\mathbf{C}_k = \frac{1}{N_k - 1} \sum_{j=1}^{N_k} (\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)(\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)^T$$

Covarianza de la clase k

N_k muestras de la clase k



Covarianza Intra-Clase (within-class covariance)


$$\mathbf{C}_w = \sum_{k=1}^K p_k \mathbf{C}_k,$$

Promedio ponderado de las Covarianzas de la cada clase


$$\mathbf{C}_k = \frac{1}{N_k - 1} \sum_{j=1}^{N_k} (\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)(\mathbf{z}_{kj} - \bar{\mathbf{z}}_k)^T$$

Covarianza de la clase k

N_k muestras de la clase k



Estrategia: **Inter-Class HIGH** + **Intra-Class LOW**



Criterio de Fisher:

Covarianza Intra-Clase

Covarianza Inter-Clase

$$\mathbf{C}_w = \sum_{k=1}^K p_k \mathbf{C}_k,$$

DEBE SER BAJA!

$$\mathbf{C}_b = \sum_k p_k (\bar{\mathbf{z}}_k - \bar{\mathbf{z}})(\bar{\mathbf{z}}_k - \bar{\mathbf{z}})^T$$

DEBE SER ALTA!

$$J = \text{spur} (\mathbf{C}_w^{-1} \mathbf{C}_b)$$



Suma de la diagonal

Criterio de Fisher

Se pueden clasificar
clases

clasificación de K

RECORDAR:


La variable J es un escalar que mide la separabilidad entre las clases (dado un conjunto de características)

son de $m \times m$, J es un escalar

$$J = \text{spur} (\mathbf{C}_w^{-1} \mathbf{C}_b)$$

Suma de la diagonal

Ejemplos



Algoritmo “Clean” (paso “0”)


(este paso debe realizarse antes de cualquier algoritmo de selección de características y cualquier normalización)

1. Calcular la correlación entre columnas de X
2. Si hay columnas altamente correlacionadas, selecciona una al azar y elimina el resto
3. Eliminar características constantes
(desviación estándar $< 10^{-8}$)

Métodos de Selección

1. Búsqueda Exhaustiva
2. SFS (búsqueda hacia adelante)
3. SBS (búsqueda hacia atrás)
4. Plus r Take Away s
5. Branch & Bound

Ejemplo:
de 9 características, seleccionar 3



Métodos de Selección

de 9 características,
seleccionar 3

1. **Búsqueda Exhaustiva**
2. SFS (búsqueda hacia adelante)
3. SBS (búsqueda hacia atrás)
4. Plus r Take Away s
5. Branch & Bound





Todas combinaciones de tres:


$$\binom{9}{3} = \frac{9!}{6!3!} = 84$$


Para $m = 20$, hay 1140 combinaciones


	2	3
	2	4
	2	5
	2	6
	2	7
	2	8
	2	9
	3	4
	3	5
	3	6
	3	7
	3	8
	3	9
	4	5
	4	6
	4	7
	4	8
	4	9
	5	6
	5	7
	5	8
	5	9
	6	7









































Exhaustive Search Algorithm - Example

Example: Selection of 3 features from 9

```
score_max = 0
for i1 = 1,2, ... 7
    for i2 = i1+1, ... 8
        for i3 = i2+1,... 9
            Xsel = X(:,(i1,i2,i3))
            score = fscore(Xsel)           # evaluation of the score
            if score > score_max
                sel_indices = (i1,i2,i3)
                score_max = score          # update maximum
            end
        end
    end
end

OUTPUT: sel_indices
```

Exhaustive Search Algorithm - General

Selection of p features from m

S = *all combinations of p numbers taken from m numbers**

N = *number of combinations*

```
score_max = 0                                     # initialization
for j = 1 to N                                     # evaluation of all combinations
    sj = S(j,:)                                    # columns of X
    score = fscore(X(:,st),d)                       # evaluation of the score
    if score > score_max
        sel_indices = sj
        score_max = score                           # update maximum
    end
end
```


OUTPUT: sel_indices


* In Matlab: nchoosek, in Python: scipy.misc.comb


Métodos de Selección


1. Búsqueda Exhaustiva
- 2. SFS (búsqueda hacia adelante)**
3. SBS (búsqueda hacia atrás)
4. Plus r Take Away s
5. Branch & Bound


de 9 características,
seleccionar 3


































$$J_{\max} = 1.47$$




























$$J_{\max} = 3.63$$





















$$J_{\max} = 3.94$$



8

7

9



Características seleccionadas

SFS Algorithm

```
s = [ ]
a = ones(m,1)
Jmax = 0
for j = 1 to p
    for k = 1 to m
        if a(k) == 1
            st = [s, k]
            J = score(X(st,:),d)
            if J > Jmax
                kmax = k
                Jmax = J
            end
        end
    end
    a(kmax) = 0
    s = [s, kmax]
end
```

```
# selected features
# the m features are available
# initialization
# p features to be selected
# X has m features
# is feature k available?
# columns of X
# evaluation of the score

# update maximum

# selected feature is no available
# update selected features
```

Métodos de Selección

1. Búsqueda Exhaustiva
2. SFS (búsqueda hacia adelante)
- 3. SBS (búsqueda hacia atrás)**
4. Plus r Take Away s
5. Branch & Bound


Métodos de Selección

1. Búsqueda Exhaustiva
2. SFS (búsqueda hacia adelante)
3. SBS (búsqueda hacia atrás)
4. **Plus r Take Away s**
5. Branch & Bound

Métodos de Selección

1. Búsqueda Exhaustiva
2. SFS (búsqueda hacia adelante)
3. SBS (búsqueda hacia atrás)
4. Plus r Take Away s
5. **Branch & Bound**

de 5 características,
seleccionar 3




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores

(sacando 0)

Level 0




(sacando 1)

Level 1




(sacando 2)


Level 2




Problem Statement: Given 5 features (1,2,3,4,5), select the best 3




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




En el Level 2 están todas las combinaciones posibles de 3 características.


Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Mejor J = 77 usando 123

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Mejor J = 77 usando 123

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor J = 78 usando 125


Como $78 > 77$, la selección 125 es mejor que la 123

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor J = 78 usando 125


Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor J = 78 usando 125


No es necesario evaluar los tríos
145, 135 y 134 porque J será < 60
entonces J será < 78

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores




Mejor $J = 78$ usando 125

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor $J = 78$ usando 125


Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor J = 78 usando 125

No es necesario evaluar los tríos 345, 235 y 234 porque J será < 65 entonces J será < 78


Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores



Mejor J = 78 usando 125

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores


Encontramos el máximo global tras 8 evaluaciones (usando B&B)



Mejor J = 78 usando 125

Problema: Dadas 5 características (1,2,3,4,5), selecciona las 3 mejores

Encontramos el máximo global tras 10 evaluaciones (usando Búsqueda Exhaustiva)



Mejor J = 78 usando 125