

Reconocimiento de Patrones

Versión 2026




PCA

(CAPÍTULO 3 – PR03B)

Domingo Mery 

Ciencia de la Computación
Universidad Católica – Chile
<http://domingomery.ing.uc.cl>



Repaso

Valores Propios: λ_l

$\mathbf{C}$: Matriz de $L \times L$

$$|\mathbf{C} - \lambda_l \mathbf{I}| = 0 \quad \lambda_l : \text{valores propios de } \mathbf{C}$$
$$l = 1, 2, \dots, L$$

$$\{\lambda_l\} = e_{val}(\mathbf{C})$$

Ejemplo:

calcular valores propios de $\mathbf{C} = \begin{bmatrix} 4 & 3 \\ 1 & 2 \end{bmatrix}$

$$|\mathbf{C} - \lambda_l \mathbf{I}| = 0$$

$$|\mathbf{C} - \lambda \mathbf{I}| = \begin{vmatrix} 4 - \lambda & 3 \\ 1 & 2 - \lambda \end{vmatrix} = (4 - \lambda)(2 - \lambda) - 3$$

$$\lambda^2 - 6\lambda + 5 = 0 \quad \lambda_1 = 5, \lambda_2 = 1.$$

Vectores Propios: $\mathbf{v}_l$

$$\mathbf{C}\mathbf{v}_l = \lambda_l \mathbf{v}_l \quad \mathbf{V}_l: \text{vectores propios de } L \times 1$$

Como hay infinitas soluciones: s.t. $||\mathbf{v}_l|| = 1$

$\{\mathbf{v}_l\}$ son vectores ortonormales:

$$\mathbf{v}_l^T \mathbf{v}_k = \begin{cases} 1 & \text{si } l = k \\ 0 & \text{en caso contrario} \end{cases}$$

$$\{\mathbf{v}_l\} = e_{vec}(\mathbf{C})$$

Matriz de Vectores Propios: $\mathbf{A}$

$$\mathbf{A} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_L] : \text{Matriz de } L \times L$$

$$\mathbf{A} = e_{mat}(\mathbf{C})$$

Propiedades:

$$\mathbf{A}\mathbf{A}^T = \mathbf{I} \quad \longleftarrow \quad \mathbf{v}_l^T \mathbf{v}_k = \begin{cases} 1 & \text{si } l = k \\ 0 & \text{en caso contrario} \end{cases}$$

$$\mathbf{C}\mathbf{A} = [\lambda_1 \mathbf{v}_1 \ \lambda_2 \mathbf{v}_2 \ \cdots \ \lambda_L \mathbf{v}_L] \quad \longleftarrow \quad \mathbf{C}\mathbf{v}_l = \lambda_l \mathbf{v}_l$$

Transformaciones Lineales


$$y_1 = a_{11}x_1 + a_{12}x_2 + \cdots + a_{1N}x_N$$

$$y_2 = a_{21}x_1 + a_{22}x_2 + \cdots + a_{2N}x_N$$

:

$$y_N = a_{N1}x_1 + a_{N2}x_2 + \cdots + a_{NN}x_N$$

$$\mathbf{y} = \mathbf{A}\mathbf{x}$$



- Ángulo entre y_1 e y_2 no necesariamente es 90°
- En esta transformación el origen coincide
- Si se necesita desplazar origen es necesario agregar $+a_{i0}$ a la fila i

Promedio y Varianza:

$$\mathbf{x} = [x_1 \ x_2 \ \cdots \ x_N]^T \quad \text{de } N \times 1$$

(promedio)

$$\bar{x} = \frac{1}{N} \sum_{i=1}^N x_i$$

(varianza)

$$\sigma_x^2 = \frac{1}{N-1} \sum_{i=1}^N (\bar{x} - x_i)^2$$

Covarianza:

$$\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \cdots \ \mathbf{x}_L] \quad \text{de } N \times L$$

$$\mathbf{M}_x = \underbrace{\begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix}}_{N \text{ unos}} \underbrace{\begin{bmatrix} \bar{x}_1 & \bar{x}_2 & \cdots & \bar{x}_L \end{bmatrix}}_{\bar{\mathbf{X}} \text{ promedio de cada columna de } \mathbf{X}}$$

Matriz de $N \times L$; cada columna tiene el promedio de la columna correspondiente de $\mathbf{X}$.

Covarianza:

$$\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \cdots \ \mathbf{x}_L] \quad \text{de } N \times L$$

$$\mathbf{M}_x = \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} [\bar{x}_1 \ \bar{x}_2 \ \cdots \ \bar{x}_L]$$

$$\mathbf{X}_0 = \mathbf{X} - \mathbf{M}_x \quad \text{cada columna de } \mathbf{X}_0 \text{ tiene media cero}$$

$$\mathbf{C}_x = \frac{1}{N-1} \mathbf{X}_0^\top \mathbf{X}_0 = \text{cov}(\mathbf{X})$$

Covarianza:

$$C_x(l, l) = \sigma_{x_l}^2$$

$$C_x(l, k) = \text{Covarianza de } \mathbf{x}_l \text{ con } \mathbf{x}_k = \text{COV}(\mathbf{x}_k, \mathbf{x}_l)$$

> 0 correlación positiva

$= 0$ no hay correlación


< 0 correlación negativa

$$\mathbf{C}_x = \frac{1}{N-1} \mathbf{X}_0^T \mathbf{X}_0 = \text{cov}(\mathbf{X})$$

Ejemplo: Matrices de Covarianza


C =

0.9735	0.0041
0.0041	1.0105




C =

1.1465	1.0891
1.0891	1.1604




C =

0.6013	0.9290
0.9290	1.6678



TRANSFORMACIÓN KARHUNEN-LOEVE (PCA) (1947)

La Transformada de Karhunen-Loeve (KL) es conocida como PCA (Principal Component Analysis). La idea es transformar los datos originales $\mathbf{X}$ en datos nuevos $\mathbf{Y}$ que no tengan correlación entre ellos.



Transformación KL:

$$\mathbf{X} = [\mathbf{x}_1 \ \mathbf{x}_2 \ \cdots \ \mathbf{x}_L] \quad \text{de } N \times L$$

$$\mathbf{X}_0 = \mathbf{X} - \mathbf{M}_x$$

$$\mathbf{C}_x = \frac{1}{N-1} \mathbf{X}_0^\top \mathbf{X}_0 = \text{cov}(\mathbf{X})$$

$$\mathbf{A} = e_{mat}(\mathbf{C}_x)$$

$$\mathbf{Y} = \mathbf{X}_0 \mathbf{A} \quad \leftarrow \text{Transformación KL de } \mathbf{X}$$

$$\mathbf{X} = \mathbf{Y} \mathbf{A}^\top + \mathbf{M}_x \quad \leftarrow \text{Transformación KL inversa de } \mathbf{Y}$$

($\mathbf{A}$ es ortonormal)

Interpretación de KL:

Covarianza de $\mathbf{Y}$:

$$\mathbf{C}_y = \frac{1}{N-1} \mathbf{Y}_0^T \mathbf{Y}_0 = \text{cov}(\mathbf{Y})$$

$$\mathbf{Y}_0 = \mathbf{Y} - \cancel{\mathbf{M}_y} \quad \text{Como } \mathbf{Y} = \mathbf{X}_0 \mathbf{A} \text{ y la media de las} \\ \text{columnas de } \mathbf{X}_0 \text{ es cero, entonces } \mathbf{M}_y = \mathbf{0}$$

$$\mathbf{Y}_0 = \mathbf{Y}$$

$$\mathbf{C}_y = \frac{1}{N-1} \mathbf{Y}^T \mathbf{Y} = \text{cov}(\mathbf{Y})$$

Interpretación de KL:

Covarianza de $\mathbf{Y}$:

$$= \frac{1}{N-1} (\mathbf{X}_0 \mathbf{A})^\top \mathbf{X}_0 \mathbf{A}$$

$$= \frac{1}{N-1} \mathbf{A}^\top \mathbf{X}_0^\top \mathbf{X}_0 \mathbf{A}$$

$$\mathbf{C}_y \equiv \frac{\mathbf{A}^\top \mathbf{C}_x \mathbf{A}}{N-1} = \text{cov}(\mathbf{Y})$$

Interpretación de KL:

Covarianza de $\mathbf{Y}$:

como $\mathbf{A} = e_{mat}(\mathbf{C}_x)$ entonces

$$\mathbf{A} = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_L]$$

$$\mathbf{C}_x \mathbf{A} = [\lambda_1 \mathbf{v}_1 \ \lambda_2 \mathbf{v}_2 \ \cdots \ \lambda_L \mathbf{v}_L]$$

$$\mathbf{C}_y \mathbf{G}_y = [\mathbf{v}_1 \mathbf{A} \mathbf{v}_2 \mathbf{C}_x \mathbf{A} \mathbf{v}_L]^\top [\lambda_1 \mathbf{v}_1 \ \lambda_2 \mathbf{v}_2 \ \cdots \ \lambda_L \mathbf{v}_L]$$

Interpretación de KL:

Covarianza de $\mathbf{Y}$:

$$\mathbf{C}_y = \begin{bmatrix} \lambda_1 \mathbf{v}_1^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_1^T \mathbf{v}_2 & \dots & \lambda_L \mathbf{v}_1^T \mathbf{v}_L \\ \lambda_1 \mathbf{v}_2^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_2^T \mathbf{v}_2 & \dots & \lambda_L \mathbf{v}_2^T \mathbf{v}_L \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 \mathbf{v}_L^T \mathbf{v}_1 & \lambda_2 \mathbf{v}_L^T \mathbf{v}_2 & \dots & \lambda_L \mathbf{v}_L^T \mathbf{v}_L \end{bmatrix}$$
$$\mathbf{C}_y = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_L]^T [\lambda_1 \mathbf{v}_1 \ \lambda_2 \mathbf{v}_2 \ \cdots \ \lambda_L \mathbf{v}_L]$$

Interpretación de KL:

Covarianza de $\mathbf{Y}$:

$$\mathbf{C}_y = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_L]^\top [\lambda_1 \mathbf{v}_1 \ \lambda_2 \mathbf{v}_2 \ \cdots \ \lambda_L \mathbf{v}_L]$$

$$\mathbf{C}_y = \begin{bmatrix} \lambda_1 \mathbf{v}_1^\top \mathbf{v}_1 = 1 & 0 & \cdots & 0 \\ 0 & \lambda_2 \mathbf{v}_2^\top \mathbf{v}_2 = 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_L \mathbf{v}_L^\top \mathbf{v}_L = 1 \end{bmatrix}$$

Interpretación de KL:



Covarianza de $\mathbf{Y}$:

$$\mathbf{C}_y = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ & \vdots & & \\ 0 & 0 & \dots & \lambda_L \end{bmatrix}$$

Generalmente, se ordena de tal forma que: $\lambda_1 > \lambda_2 > \dots > \lambda_L$


SIGNIFICADO

Ejemplo en 2D




X


Ejemplo en 5D



X




Y




Y


Ejemplo en 5D



X




Y




SIGNIFICADO EN LA TRANSFORMACIÓN DE CARACTERÍSTICAS

SELECCION DE CARACTERISTICAS



PCA



Significado de PCA:


1. $\mathbf{Y}$ es una nueva representación de $\mathbf{X}$ (es una transformación lineal de $\mathbf{X}$)

2. Las columnas de $\mathbf{Y}$ no tienen correlación: $C_y(k, l) = 0$ para $k \neq l$

3. Ordenado de mayor a menor las columnas de $\mathbf{Y}$ están ordenadas por importancia

APLICACIÓN A RECONOCIMIENTO DE PATRONES


Estrategia con PCA:




Training



Training / Testing



Training / Testing




$$X_{test_pca} = (X_{test} - Mx) \times A$$

Ventajas de PCA:

1. La representación de muchas características es mucho más sencilla ya que se reduce la dimensionalidad
2. La clasificación usando las primeras componentes es más simple y más rápida para el clasificador
3. Es posible reconstruir $\mathbf{X}$ a partir de las principales columnas de $\mathbf{Y}$.
$$\mathbf{X} = \mathbf{Y}\mathbf{A}^T + \mathbf{M}_x$$

Reconstrucción con PCA:






$\mathbf{A}_t \leftarrow$ primeras t columnas de $\mathbf{A}$

$\mathbf{Y} = \mathbf{X}_0 \mathbf{A}_t \leftarrow$ primeras t componentes principales de $\mathbf{X}$

$\hat{\mathbf{X}} = \mathbf{Y} \mathbf{A}_t^T + \mathbf{M}_x \leftarrow$ reconstrucción de $\mathbf{X}$

Reconstrucción con PCA:

t	Error
256	0.00%
200	0.08
100	0.94%
50	2.05%
30	2.93%
20	3.67%
10	5.36%
5	6.98%
2	9.10%




Desventajas de PCA:

1. Las características de PCA dependen de todas las características extraídas (es necesario extraer todas las características X para obtener Y , no hay ahorro de cómputo en la extracción)
2. PCA al no incluir información de los labels no asegura que las características transformadas tengan una buena separabilidad.

ALTERNATIVAS


Estrategia con PCA (original):




Estrategia con PCA y SFS (I/4):




Estrategia con PCA y SFS (2/4):



Estrategia con PCA y SFS (3/4):



Estrategia con PCA y SFS (4/4):



OTRAS TRANSFORMACIONES

ICA

(Independent Component Analysis)

Diferencia de ICA con PCA:

- PCA elimina correlaciones pero no otro tipo de dependencia.
- ICA elimina correlaciones y dependencias de mayor orden.
- En PCA se persigue que la covarianza entre las variables transformadas sea 0



$$\text{cov}(y_k, y_l) = 0$$

- En ICA se persigue que las variables sean independientes:

$$p(y_1, y_2, \dots, y_L) = p(y_1)p(y_2) \cdots p(y_L)$$

Diferencia de ICA con PCA:

- En PCA los vectores son ortogonales.
- En ICA los vectores no son ortogonales.



PLSR

(Partial Least Squares Regression)

Descomposición PLSR:

$$\mathbf{X} = \mathbf{T}\mathbf{P}^T + \mathbf{E} \quad \mathbf{X}: \text{Matriz de características}$$

$$\mathbf{Y} = \mathbf{U}\mathbf{Q}^T + \mathbf{F} \quad \mathbf{Y}: \text{Matriz de labels}^{(*)}$$

Las descomposiciones de $\mathbf{X}$ e $\mathbf{Y}$ se hacen con el fin de maximizar la covarianza entre $\mathbf{T}$ y $\mathbf{U}$.

Las matrices $\mathbf{P}$ y $\mathbf{Q}$ son ortogonales. Las matrices $\mathbf{E}$ y $\mathbf{F}$ corresponden al error.

La idea es buscar $\mathbf{T}$, que es la transformada de $\mathbf{X}$.

^(*) Matriz binaria de $N \times K$, $Y(i,k) = 1$ if $y(i) = k$, con K número de clases