Reconocimiento de Patrones

Versión 2026



Consideraciones Prácticas

(CAPÍTULO 5 – PR.05.A)

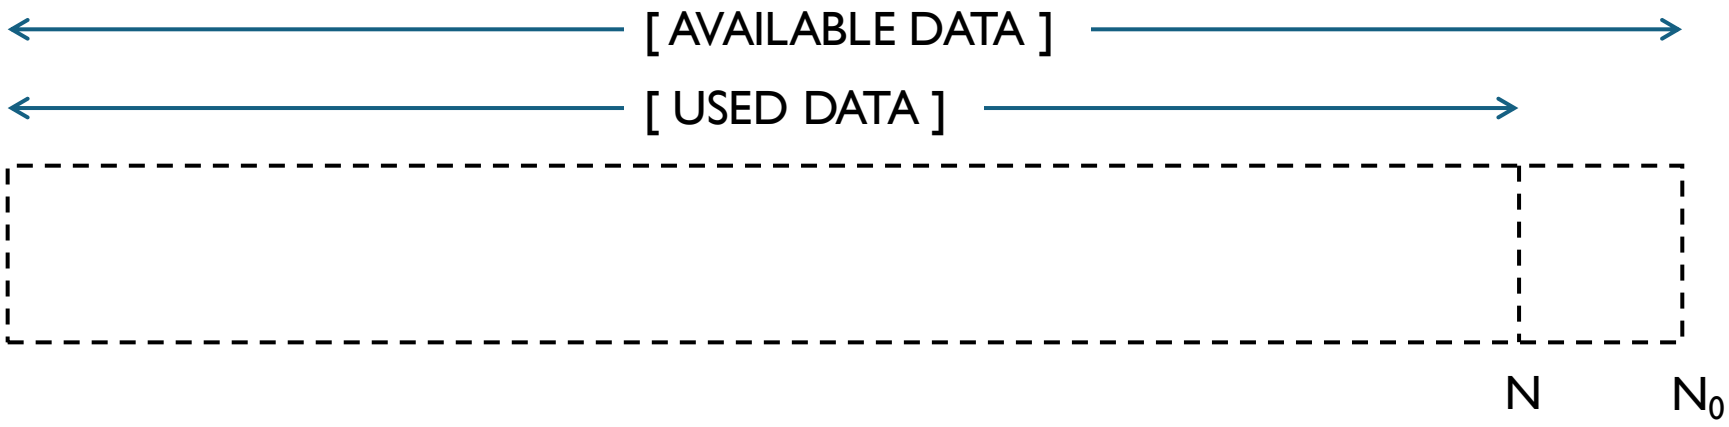
Domingo Mery

Ciencia de la Computación
Universidad Católica – Chile
http://domingomery.ing.uc.cl

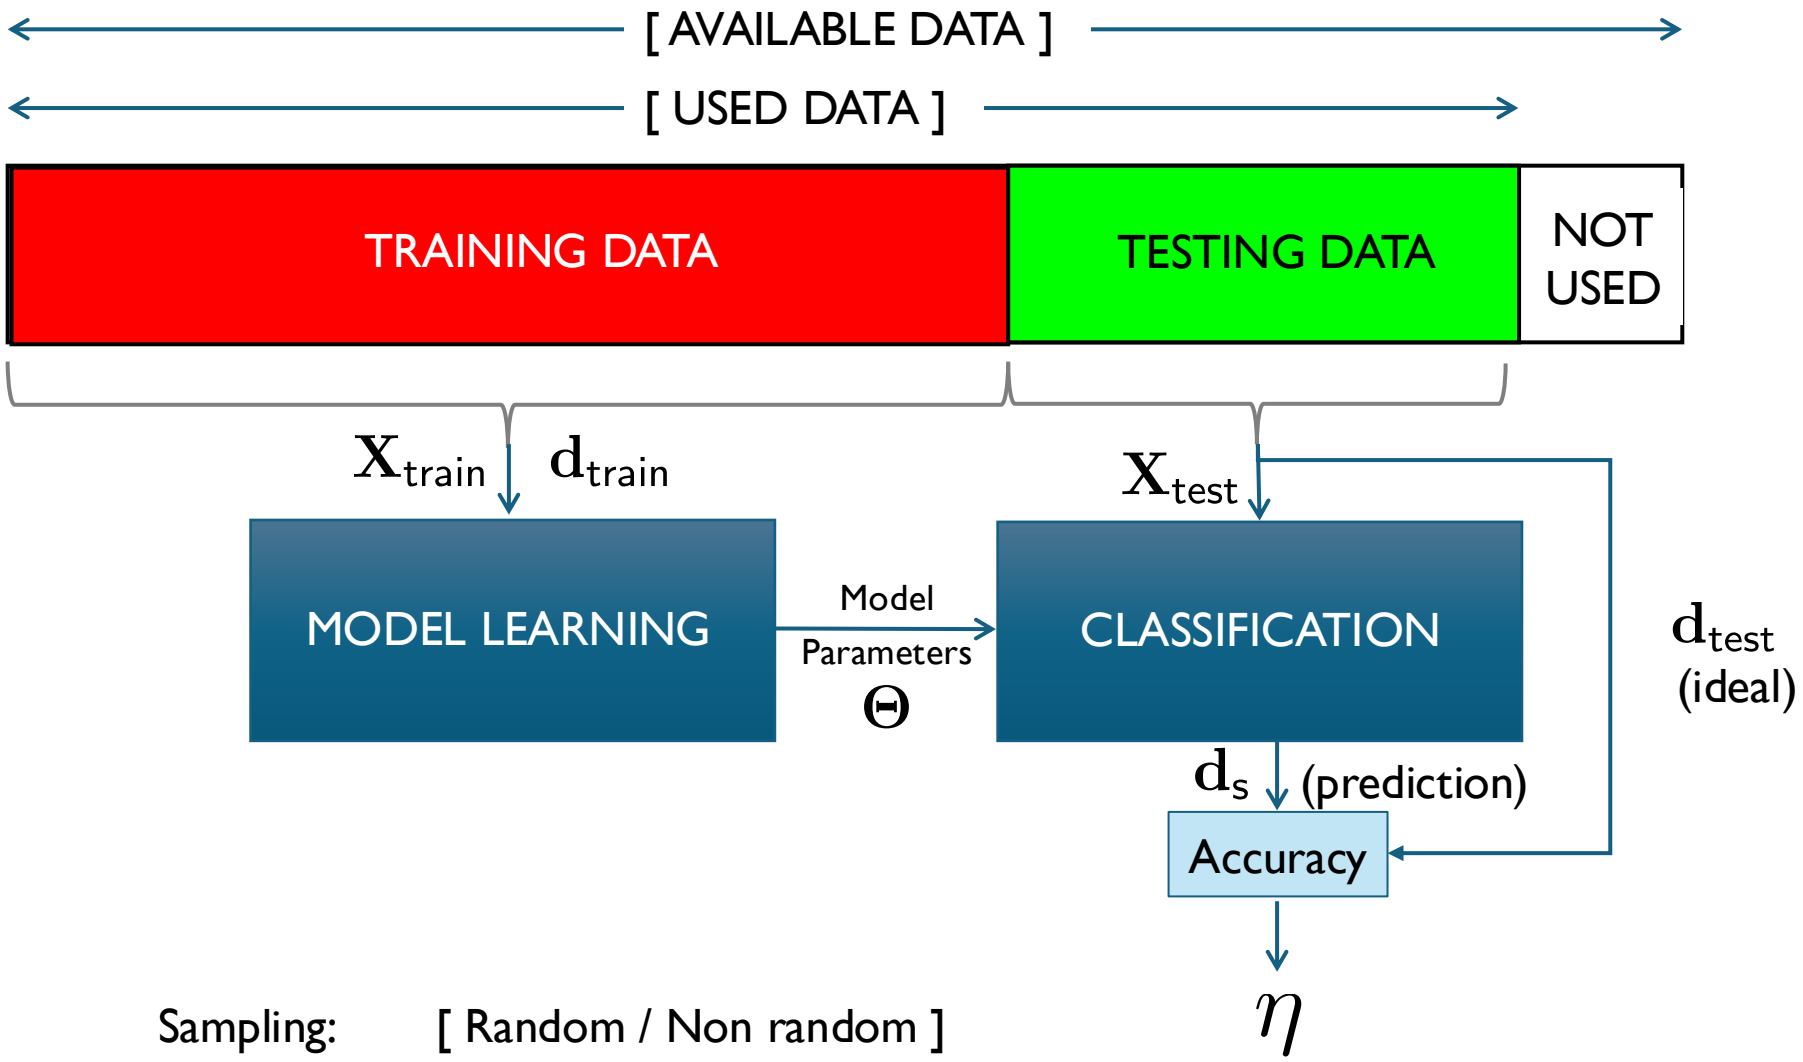
Estimación Métricas de Desempeño

(Ejemplo: Accuracy)

Estimación del Accuracy de un Clasificador



Estimación del Accuracy de un Clasificador



Sampling: [Random / Non random]
[Stratified / Non stratified]

Estimación del Accuracy de un Clasificador



Estimación del Accuracy de un Clasificador



Estimación del Accuracy de un Clasificador

HO: HOLD OUT



Estimación del Accuracy de un Clasificador

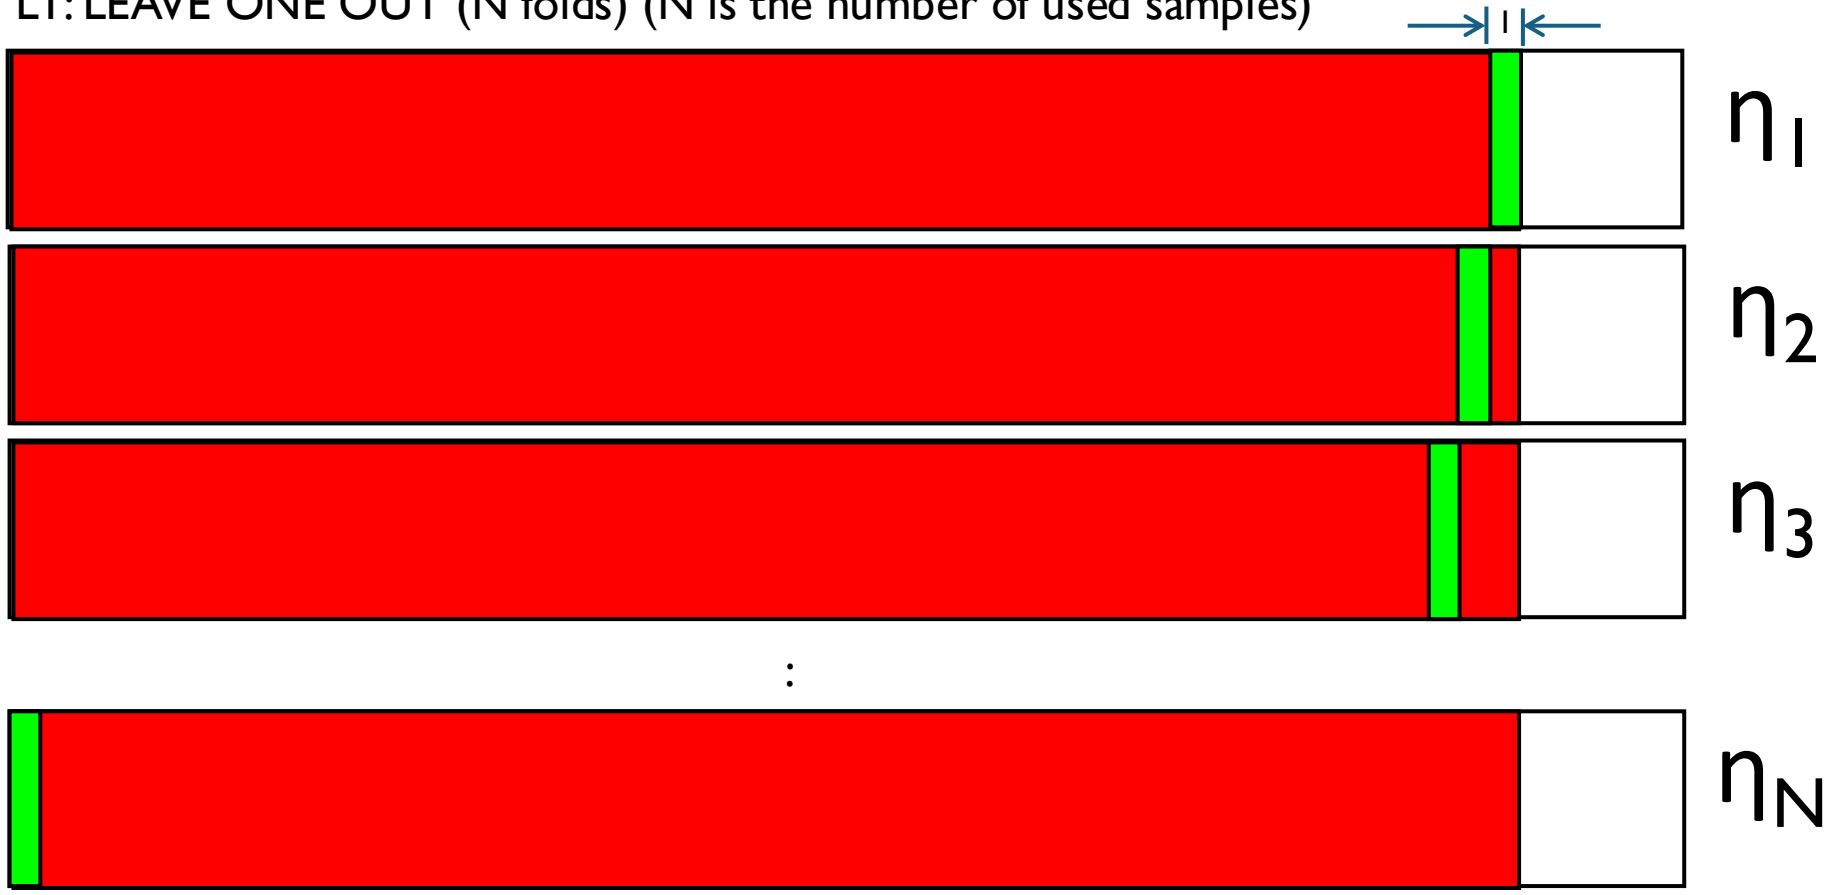
CV: CROSS VALIDATION – n folds



$$\eta = (\eta_1 + \eta_2 + \eta_3 + \ldots + \eta_n)/n$$

Estimación del Accuracy de un Clasificador

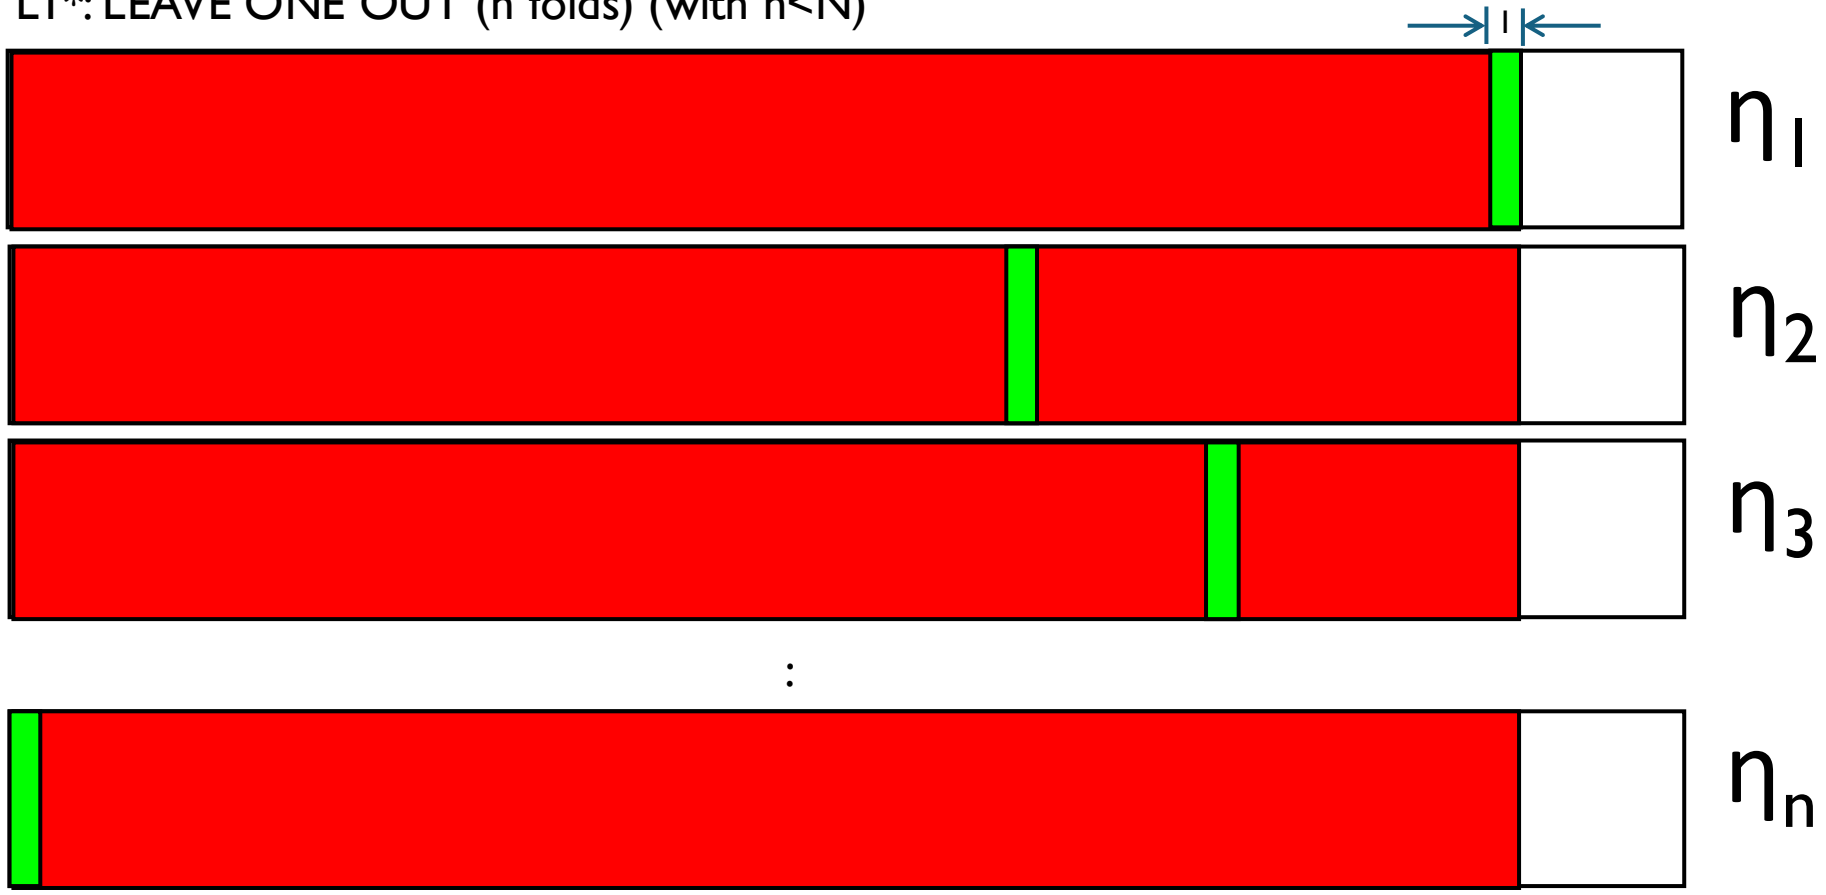
L1: LEAVE ONE OUT (N folds) (N is the number of used samples)



$$\eta = (\eta_1 + \eta_2 + \eta_3 + \ldots + \eta_N)/N$$

Estimación del Accuracy de un Clasificador

L1*: LEAVE ONE OUT (n folds) (with n<N)



$$\eta = (\eta_1 + \eta_2 + \eta_3 + \ldots + \eta_n)/n$$

Estimación del Accuracy de un Clasificador

[SIMULATED DATA]

2 Classes

2 Gaussian Distributions

$\mu_1 = (1,1)$

$\mu_2 = (-1,-1)$

$\sigma_1 = \sigma_1 = 1$

500 samples /class

$N_0 = 1000$ (available data)

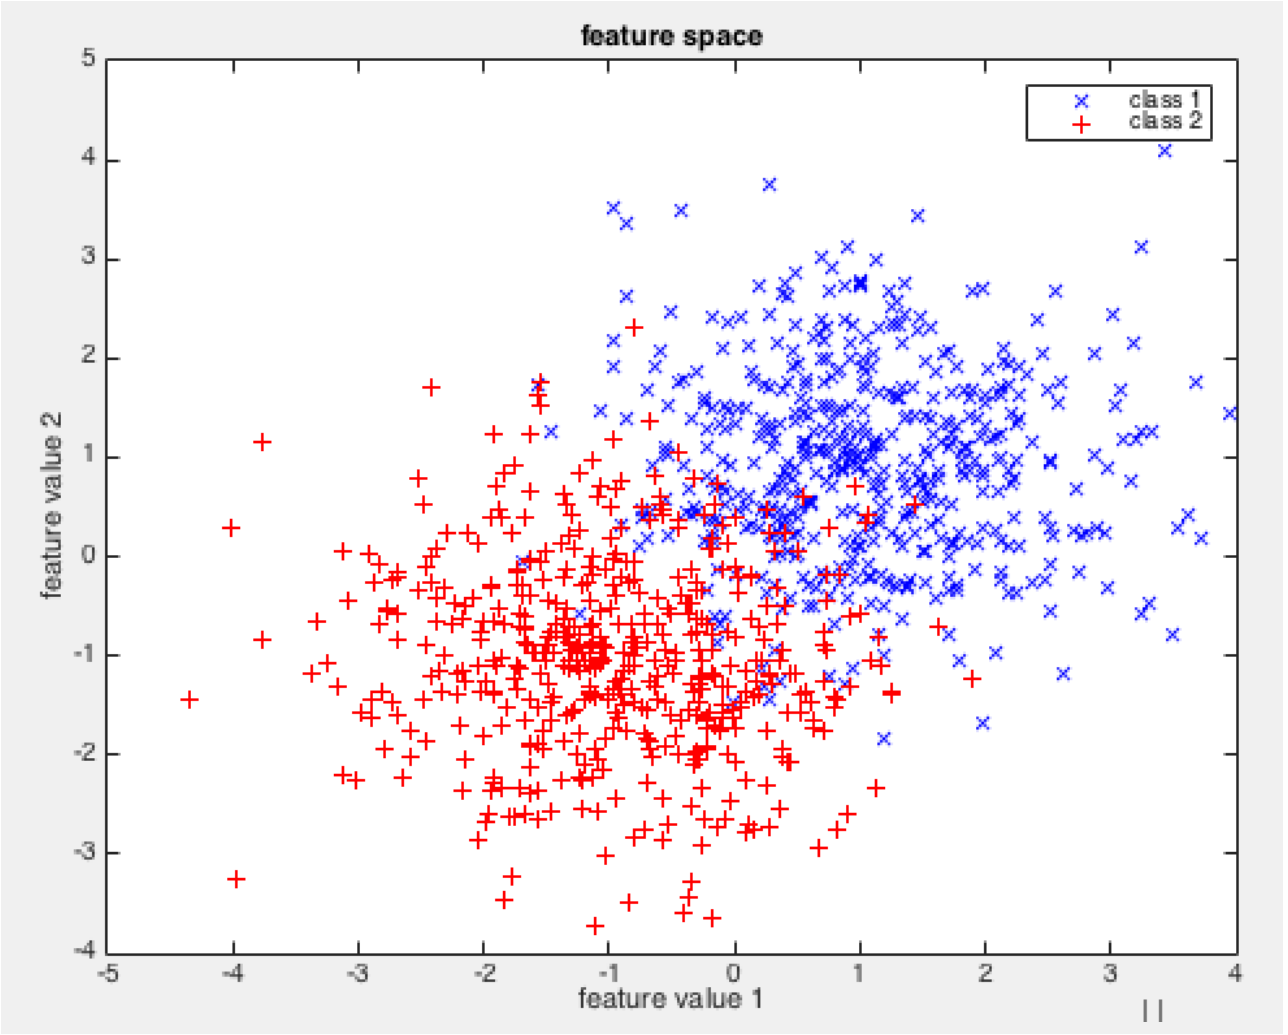
[CLASSIFIER]

Linear SVM

[SAMPLING]

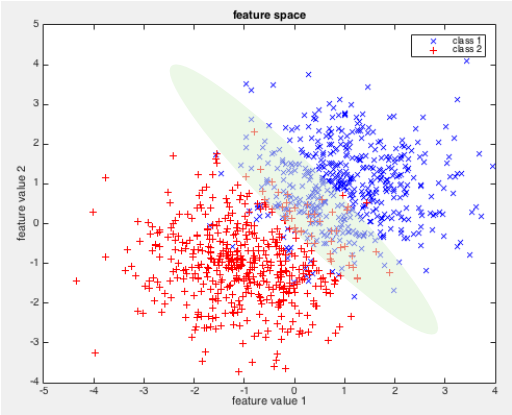
Random / Stratified

1000 Repetitions!



After 1000 Repetitions!

N_0 = 1000 (available data)
N used data



Method: Parameters	N/N_0	mean	std	min	max
HO: 90%-10%	1	acc =			
HO: 80%-20%	1	acc =			
HO: 75%-25%	1	acc =			
HO: 67%-33%	1	acc =			
HO: 50%-50%	1	acc =			
HO: 90%-10%	0.5	acc =			
HO: 80%-20%	0.5	acc =			
HO: 75%-25%	0.5	acc =			
HO: 67%-33%	0.5	acc =			
HO: 50%-50%	0.5	acc =			
HO: 90%-10%	0.1	acc =			
HO: 80%-20%	0.1	acc =			
HO: 75%-25%	0.1	acc =			
HO: 67%-33%	0.1	acc =			
HO: 50%-50%	0.1	acc =			
CV: 5-fold	1	acc =			
CV: 10-fold	1	acc =			
CV: 5-fold x 20	1	acc =			
CV: 5-fold x 10	1	acc =			
CV: 5-fold x 5	0.5	acc =			
CV: 10-fold	0.5	acc =			
CV: 5-fold x 20	0.5	acc =			
CV: 5-fold x 10	0.5	acc =			
CV: 5-fold	0.1	acc =			
CV: 10-fold	0.1	acc =			
CV: 5-fold x 20	0.1	acc =			
CV: 5-fold x 10	0.1	acc =			
L1:	1	acc =			
L1:	0.5	acc =			
L1:	0.1	acc =			
L1*: 200-fold	1	acc =			
L1*: 100-fold	1	acc =			
L1*: 50-fold	1	acc =			

Aspectos Prácticos (y éticos) en Machine Learning

GIGO: Garbage in = Garbage out

Si entrenamos los modelos con datos de mala calidad...

… No esperemos resultados de calidad



Y si sabes que tu modelo está mal, por favor no lo uses...

http://DataGeneth.BBVA.io/2016/12/27/Garbage-in,-garbage-out.-A-developer-story.html

(c) Dr. Jerry I. Ponce

Muestreo: Considerar la demografía



Si el problema es detectar una enfermedad que afecta por igual a hombres y mujeres.

Muestreo: Considerar la demografía



Entonces incluye a hombres y mujeres en tu conjunto de datos...

Muestreo: Considerar la demografía



Entonces incluye a hombres y mujeres en tu conjunto de datos...

Splitting: Considerar grupos “disjuntos”

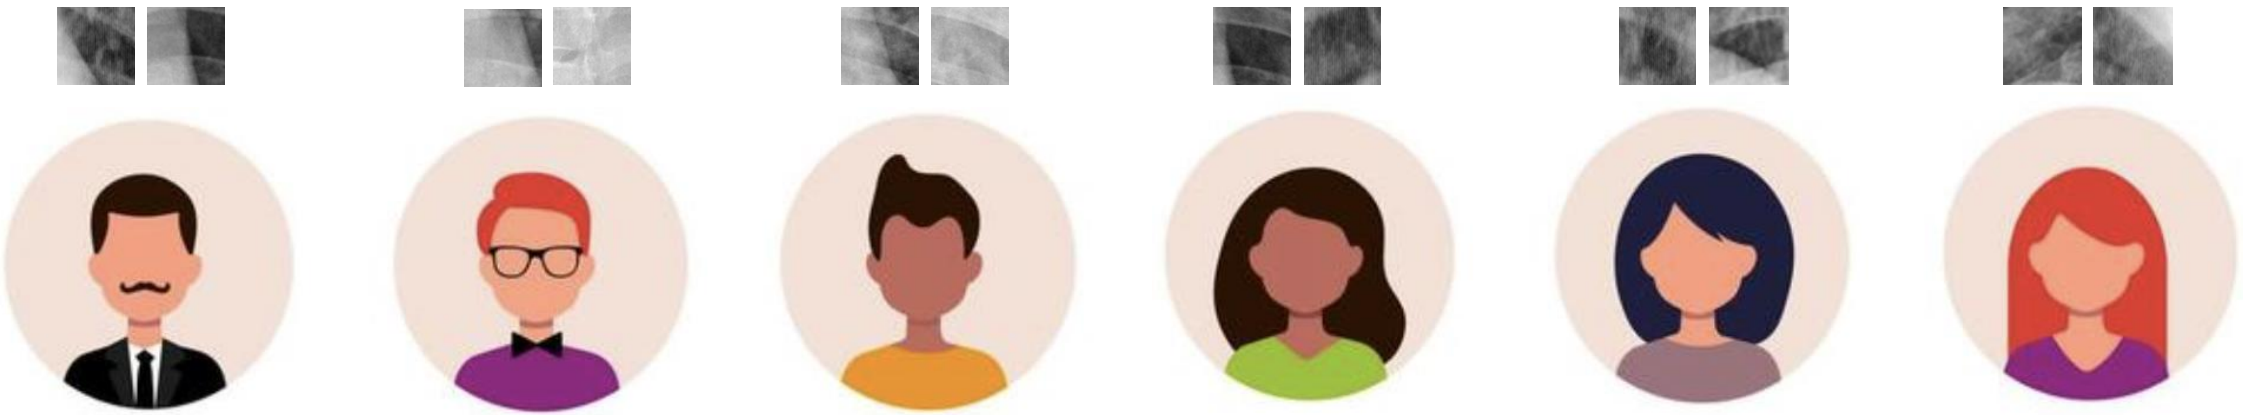
Splitting: Considerar grupos “disjuntos”

1. SELECTION OF PEOPLE



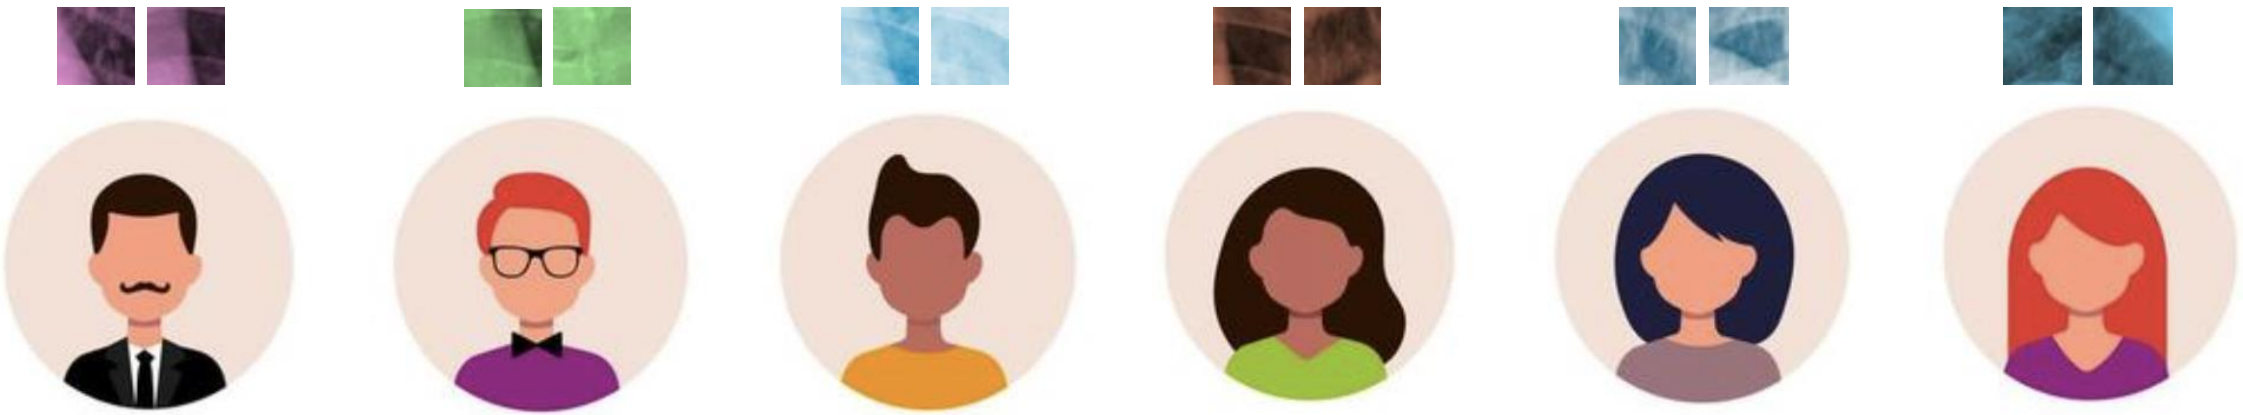
Splitting: Considerar grupos “disjuntos”

1. SELECTION OF PEOPLE
2. ACQUISITION



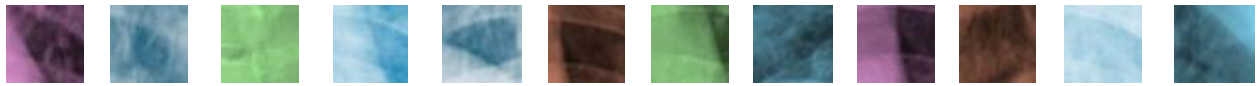
Splitting: Considerar grupos “disjuntos”

1. SELECTION OF PEOPLE
2. ACQUISITION



Splitting: Considerar grupos "disjuntos"

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE





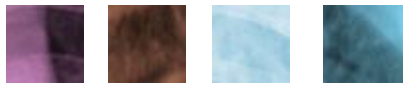
Splitting: Considerar grupos "disjuntos"

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE
4. SPLITTING

TRAINING



TESTING





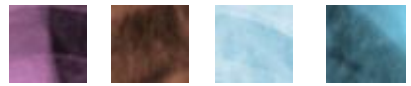
Splitting: Considerar grupos "disjuntos"

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE
4. SPLITTING

TRAINING



TESTING



TYPICAL ACCURACY > 90%



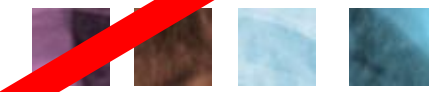
Splitting: Considerar grupos "disjuntos"

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE
4. SPLITTING

TRAINING



TESTING

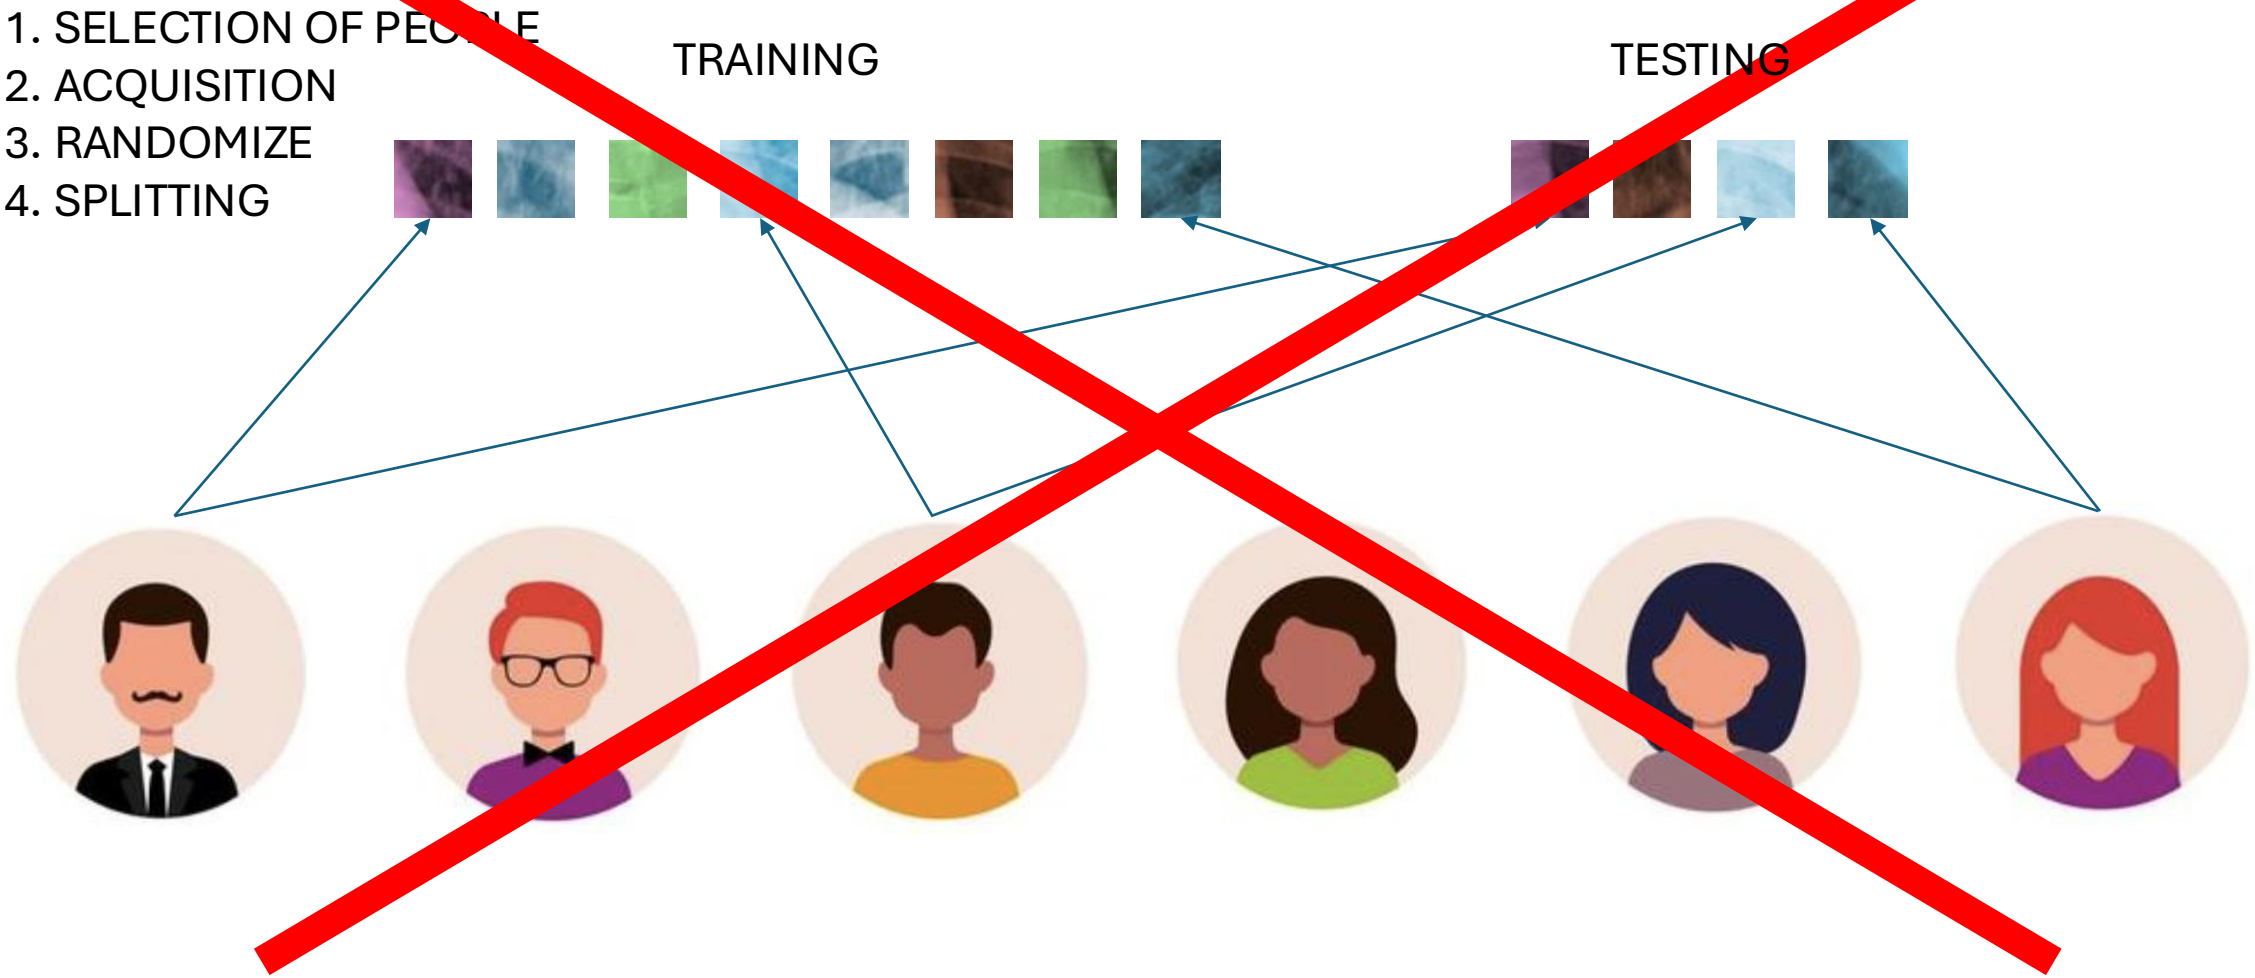


TYPICAL ACCURACY > 90%



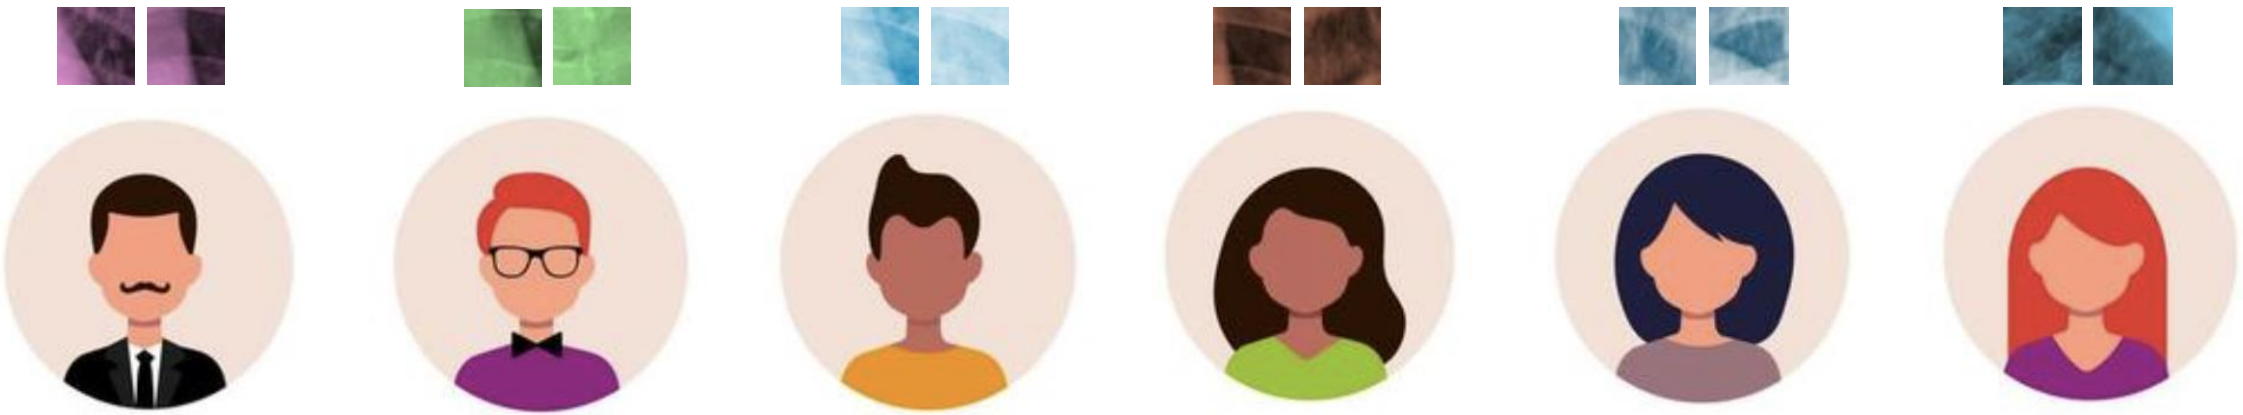
Splitting: Considerar grupos "disjuntos" POR QUÉ?

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE
4. SPLITTING



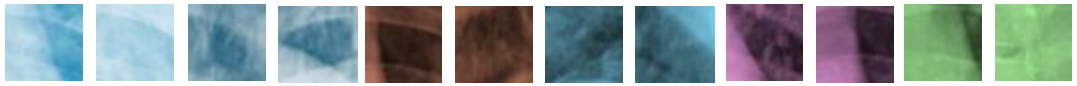
Splitting: Considerar grupos “disjuntos”

1. SELECTION OF PEOPLE
2. ACQUISITION



Splitting: Considerar grupos “disjuntos”

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE PER SUBJECT





Splitting: Considerar grupos "disjuntos"

1. SELECTION OF PEOPLE
2. ACQUISITION
3. RANDOMIZE PER SUBJECT
4. SPLITTING



TYPICAL ACCURACY < 80%



OK

Generalización: Datos Representativos

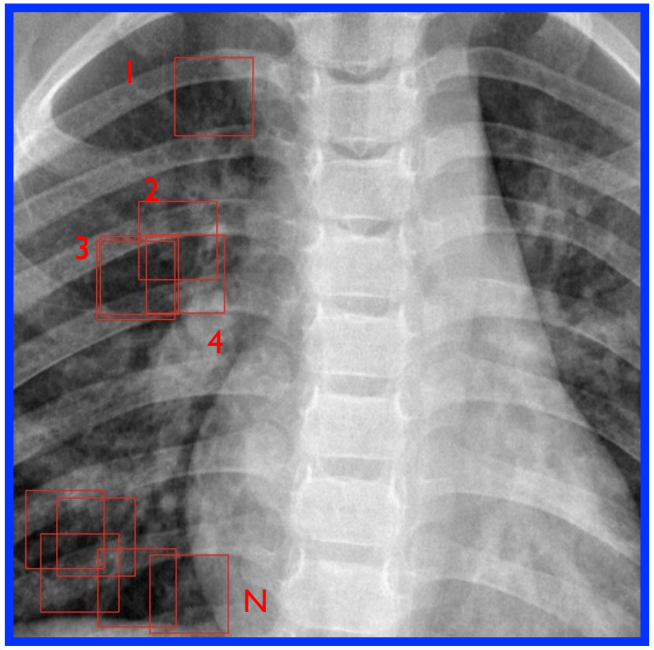
Image Classification – Example

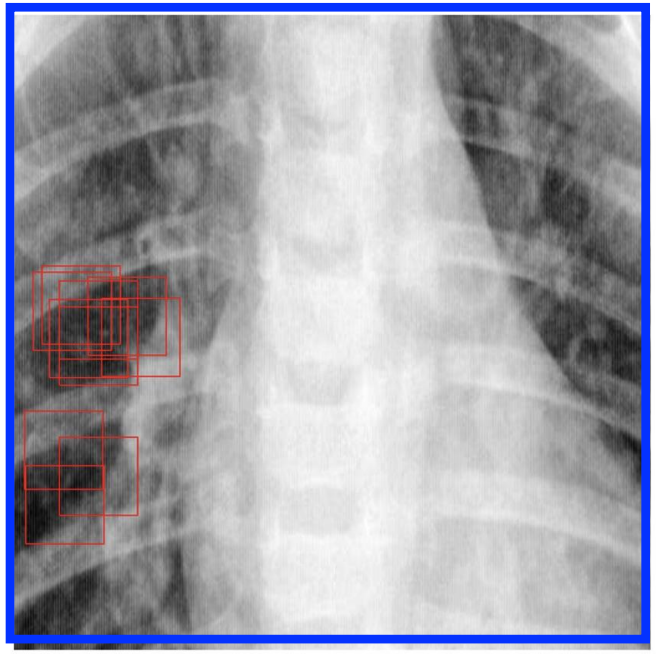
COVID Detection with Rx

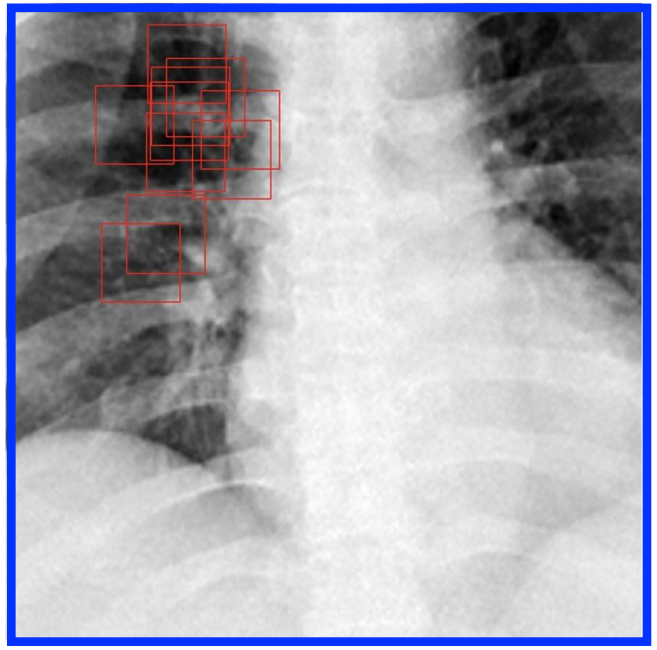
Classes → 0: NORMAL

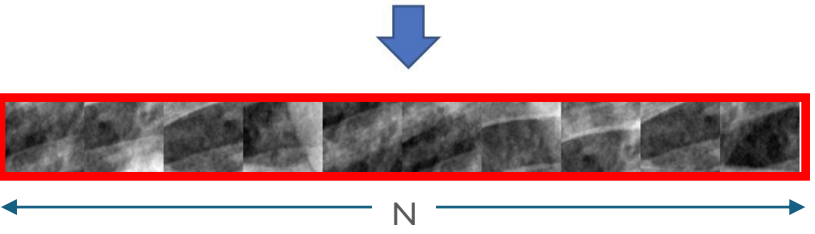
1: NEUMONIA

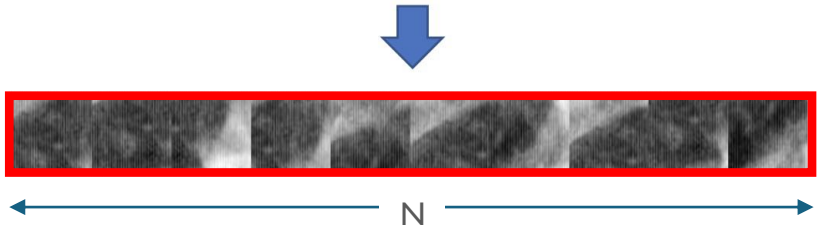
2: COVID19

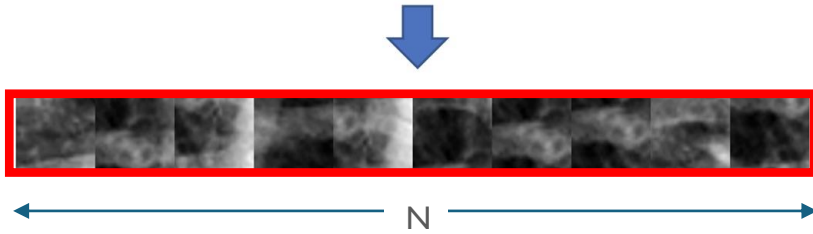




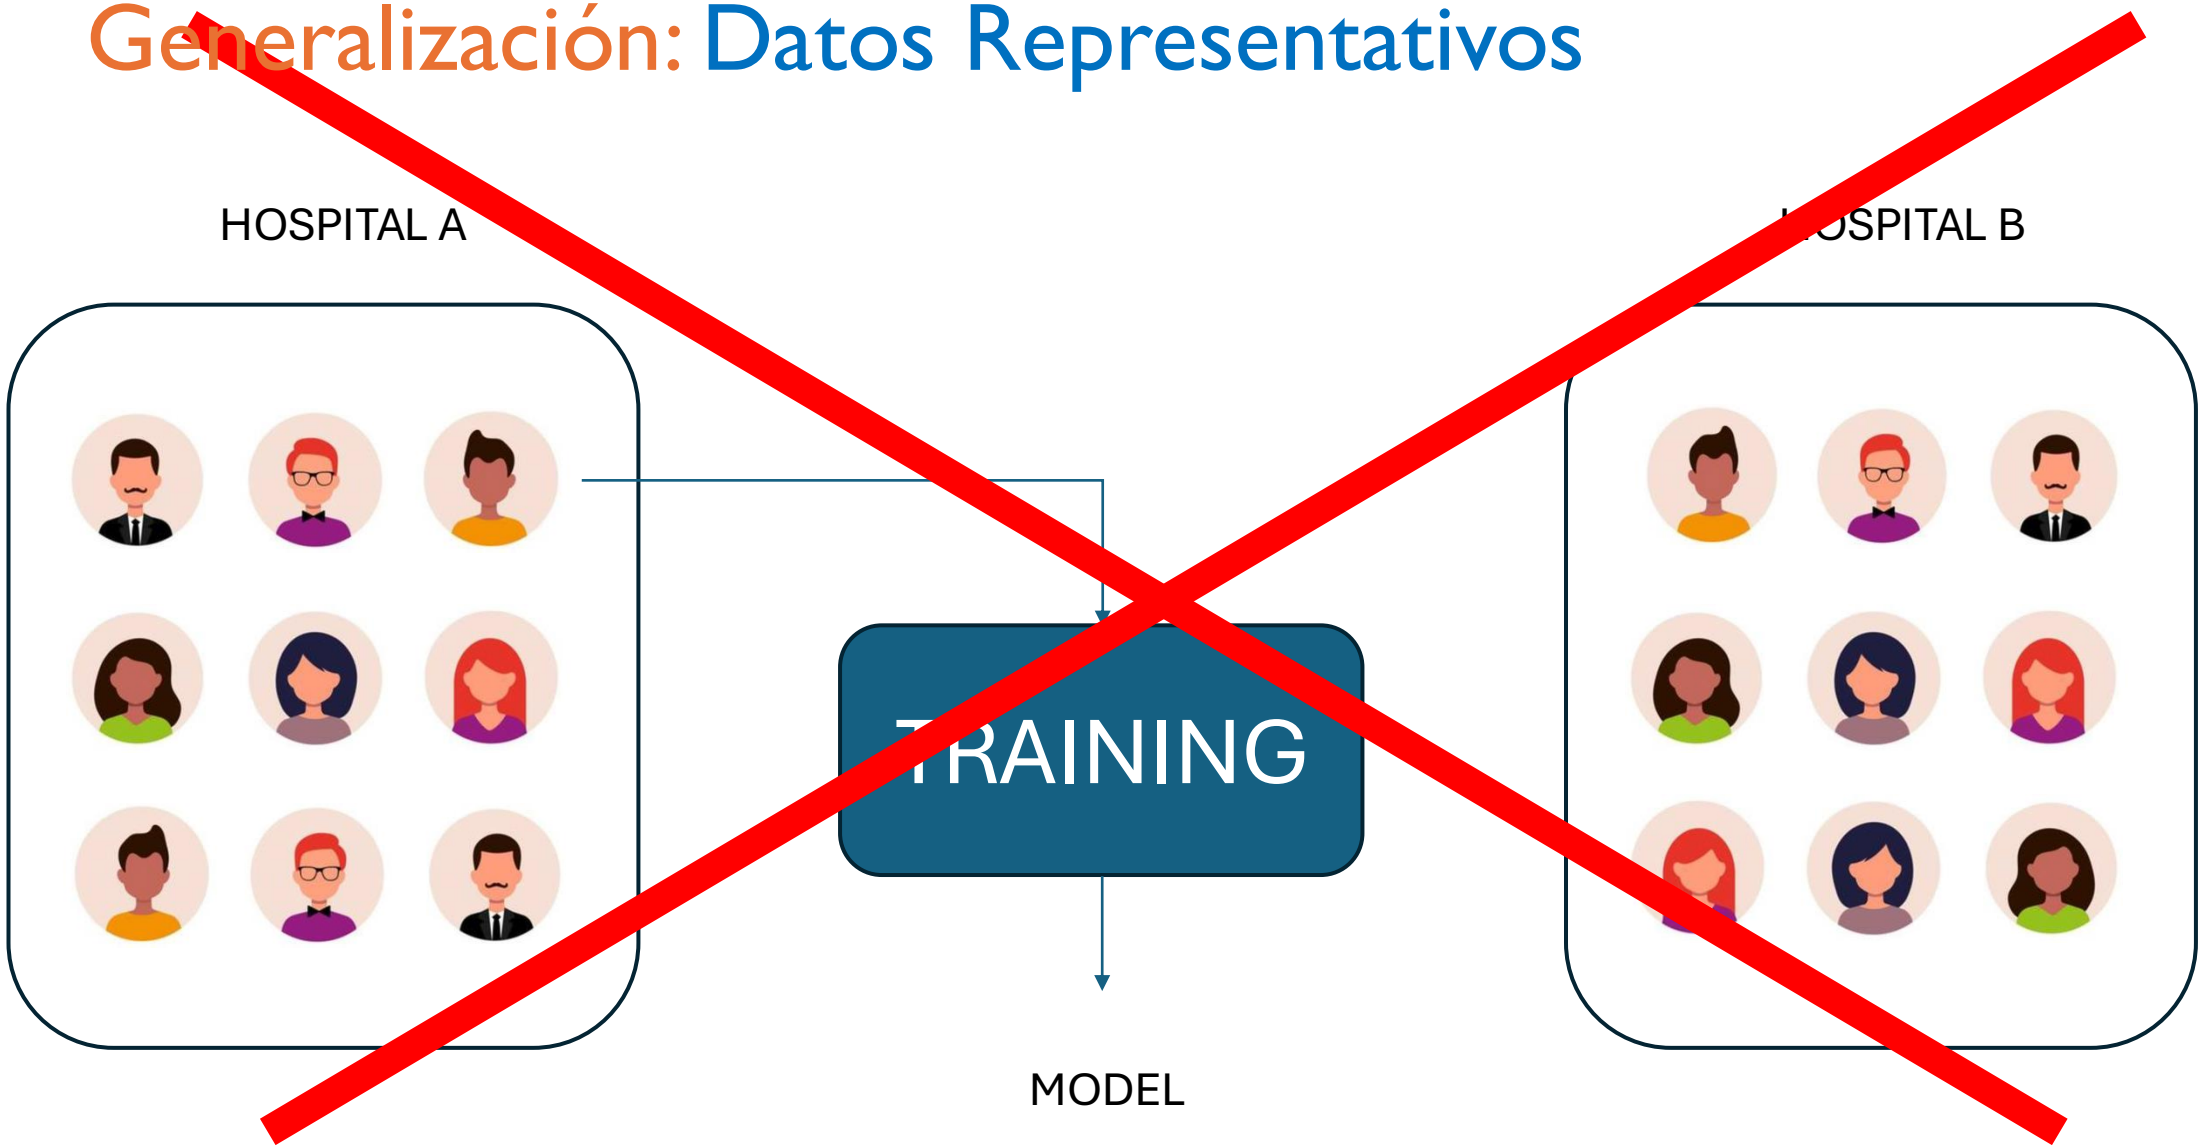




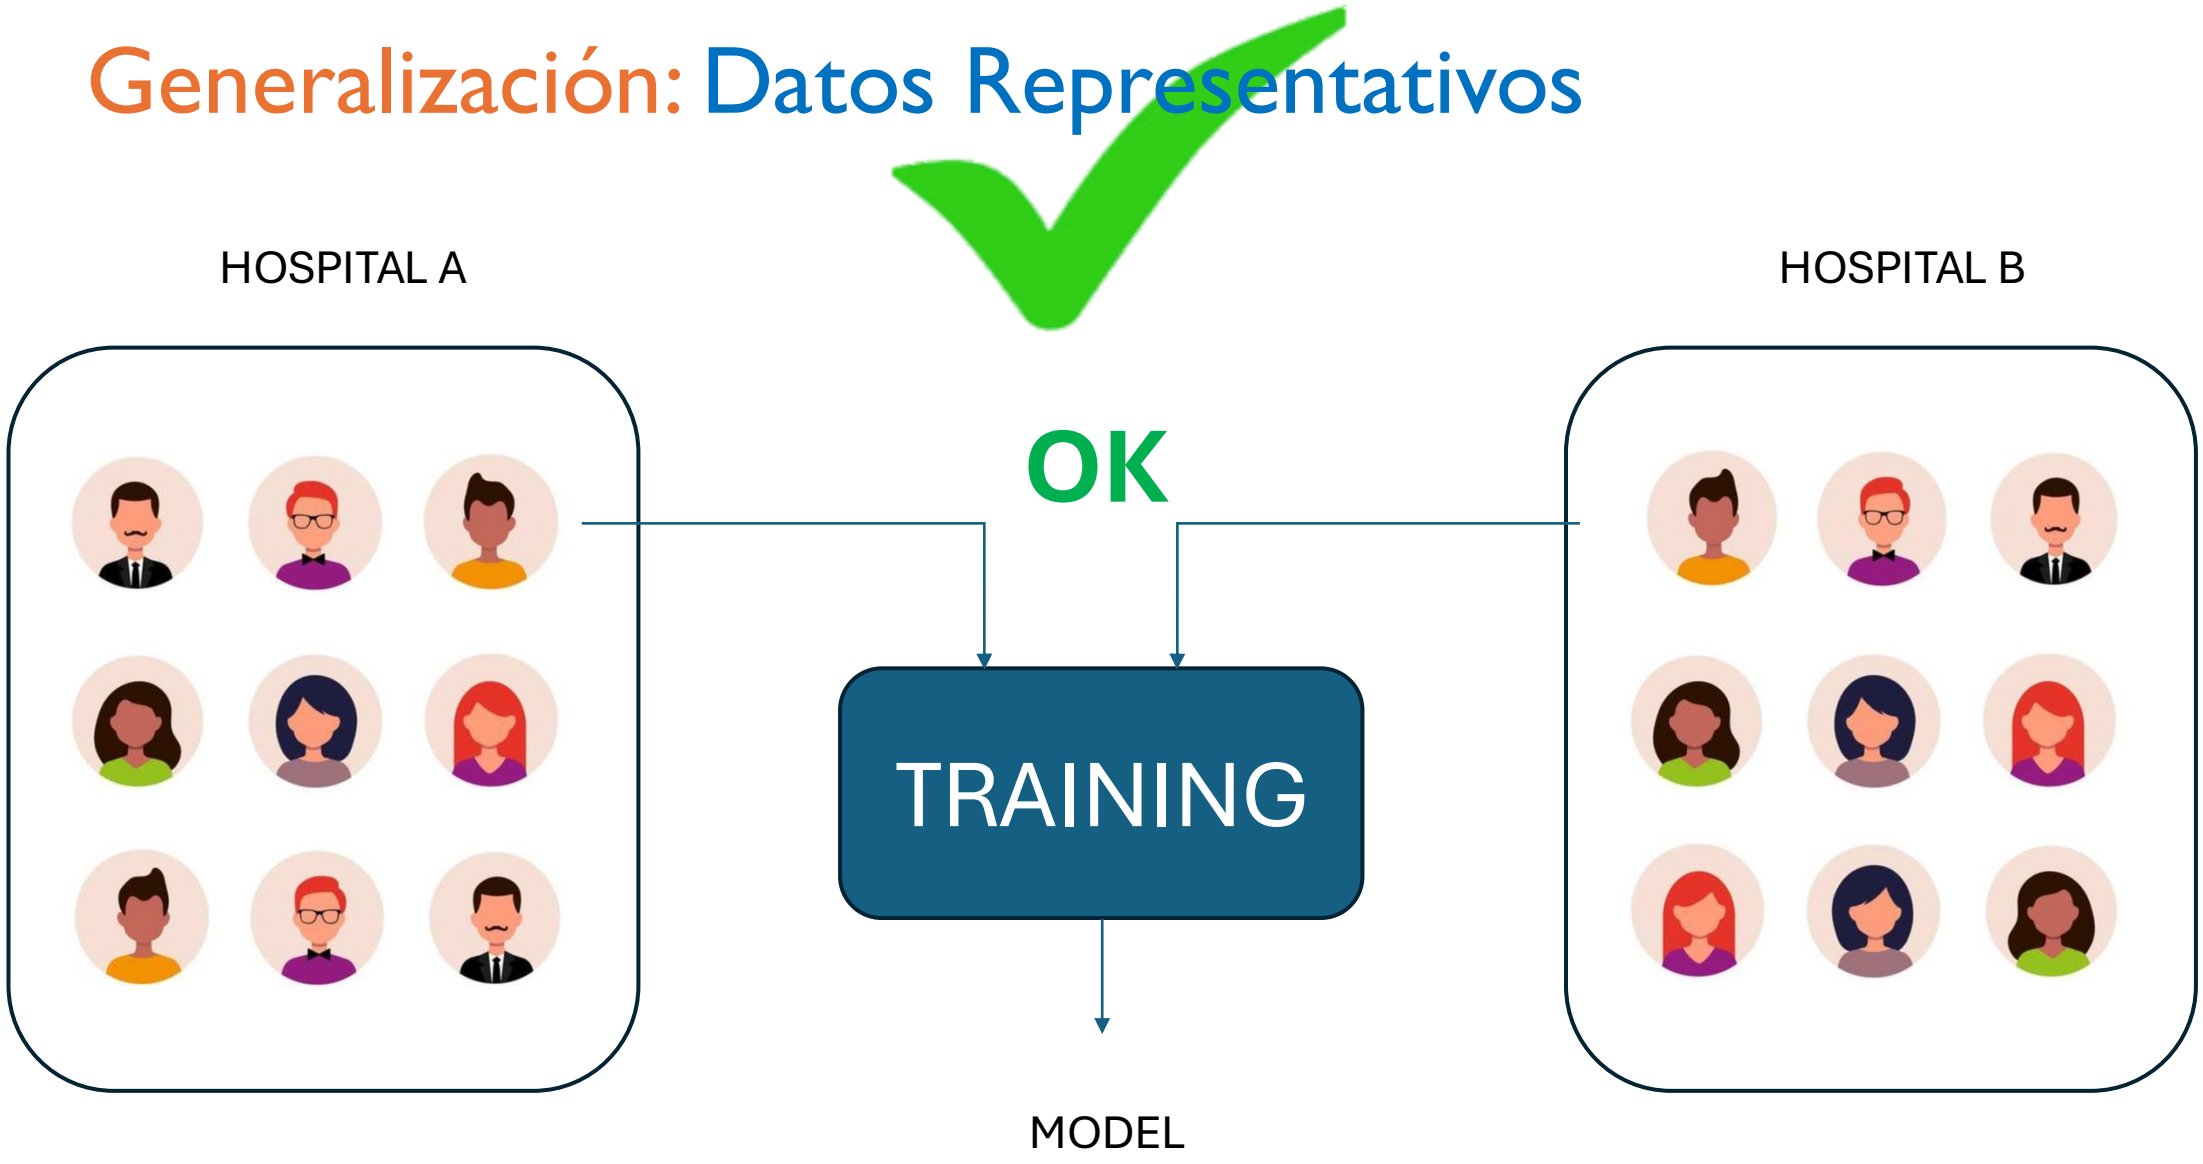




Generalización: Datos Representativos

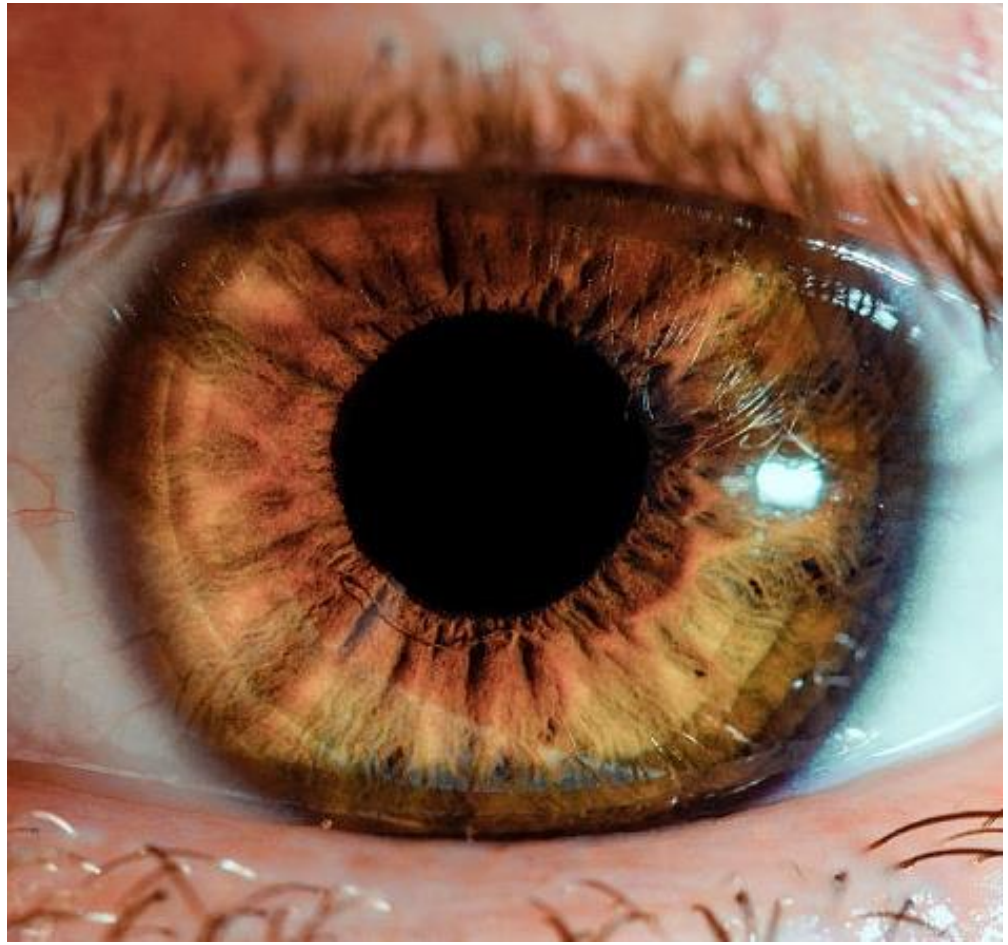


Generalización: Datos Representativos



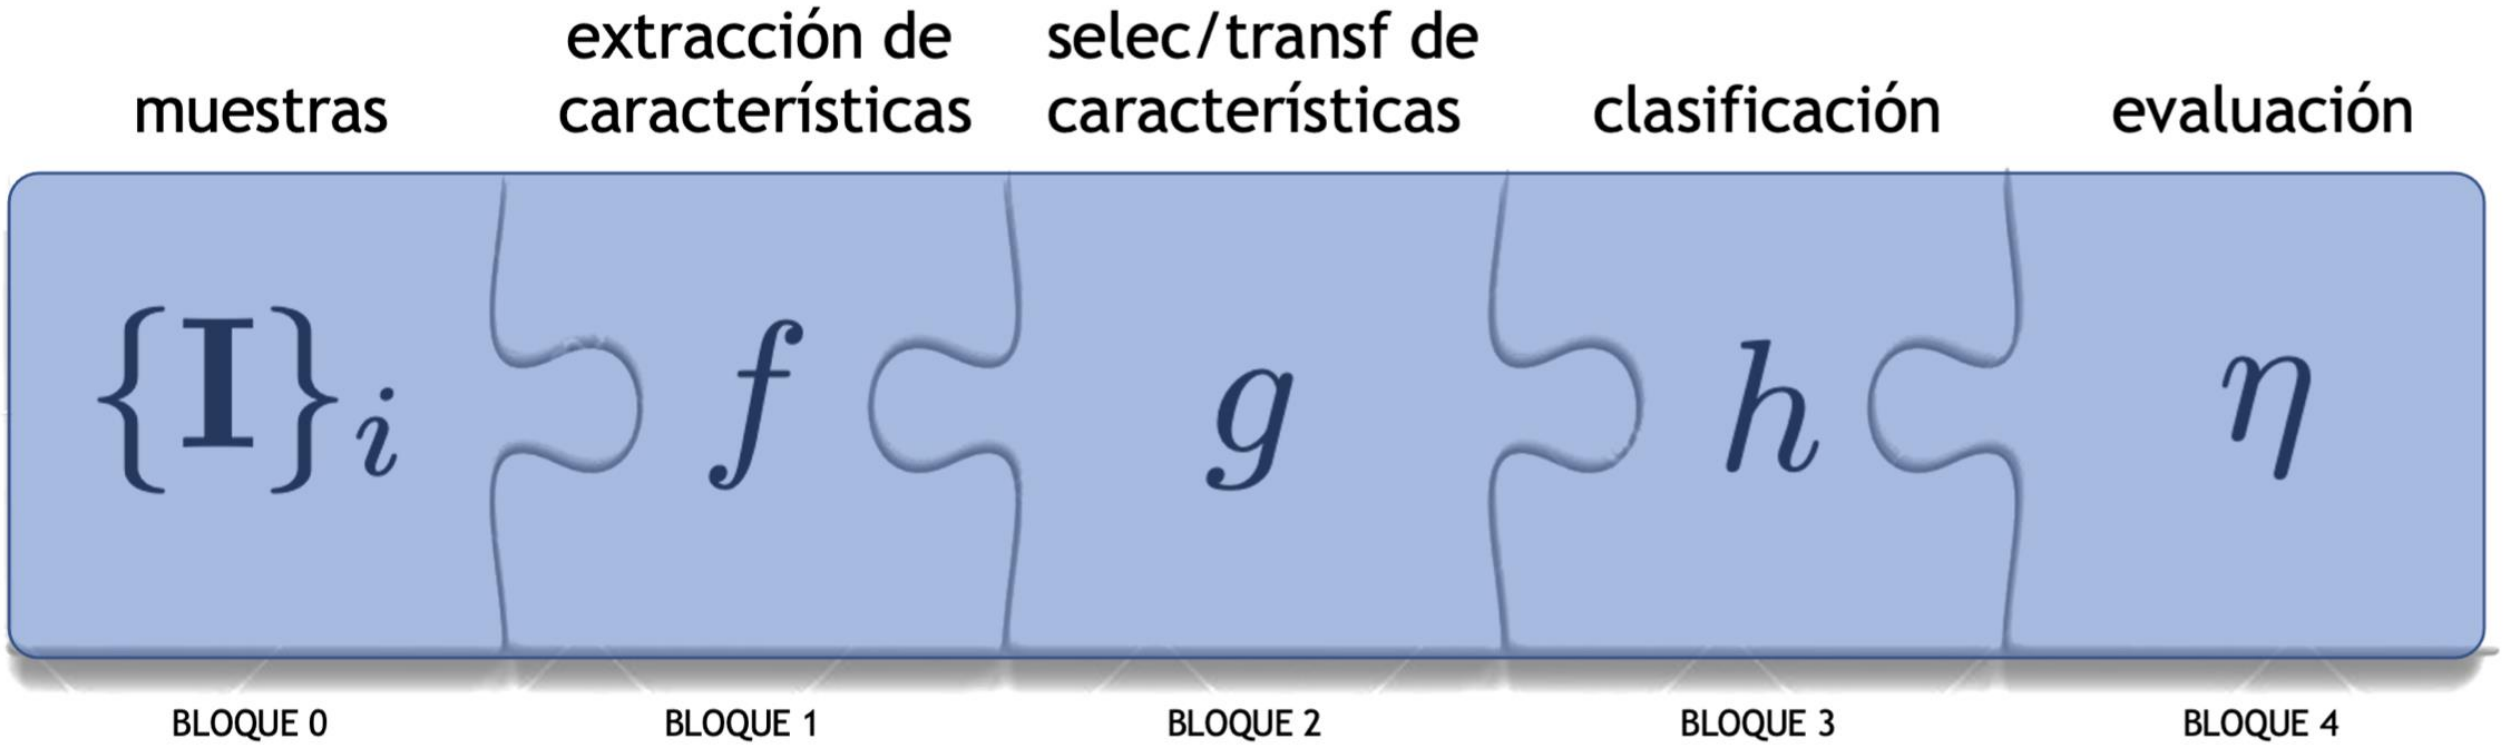
Desarrollo de un Proyecto

(Ejemplo: Reconocimiento de Iris)



PERSONA 27

AVANZAR POR BLOQUES



CADA BLOQUE GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO


muestras
extracción de características
selec/transf de características
clasificación
evaluación
$\{\mathbf{I}\}_i$
f
g
h
η
BLOQUE 0
BLOQUE 1
BLOQUE 2
BLOQUE 3
BLOQUE 4





+

- Tonos de Gris
- HSV
- Otros espacios de colores
- Otras Segmentaciones

→ CADA GRUPO DE IMÁGENES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO


muestras
extracción de características
selec/transf de características
clasificación
evaluación
$\{\mathbf{I}\}_i$
f
g
h
η
BLOQUE 0
BLOQUE 1
BLOQUE 2
BLOQUE 3
BLOQUE 4

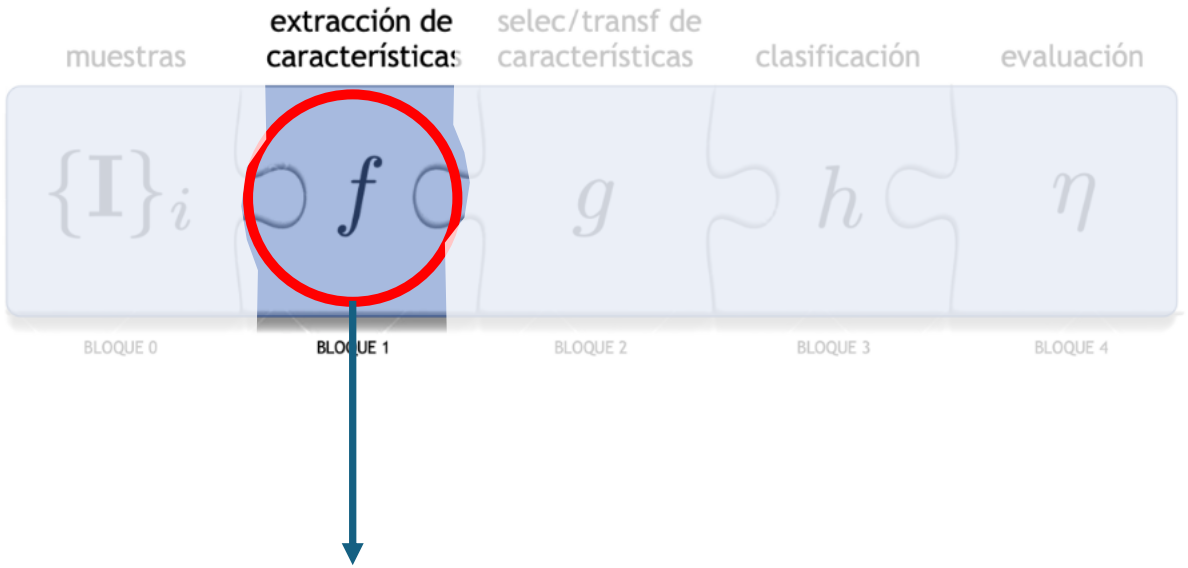


TIPO

- Geométrica
- Intensidad
- Intensidad con Geometría

EXTRAER, GUARDAR, INDEXAR

CADA GRUPO DE FEATURES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO

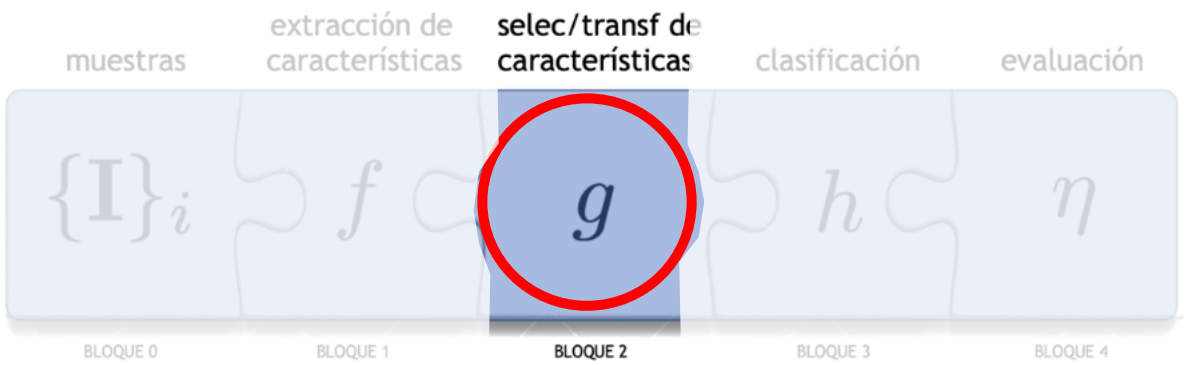


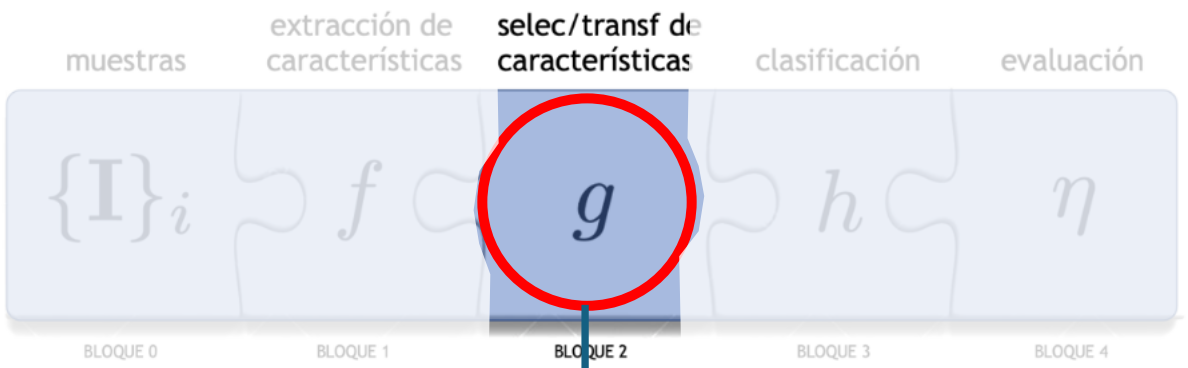

```
Crear funciones como por ejemplo

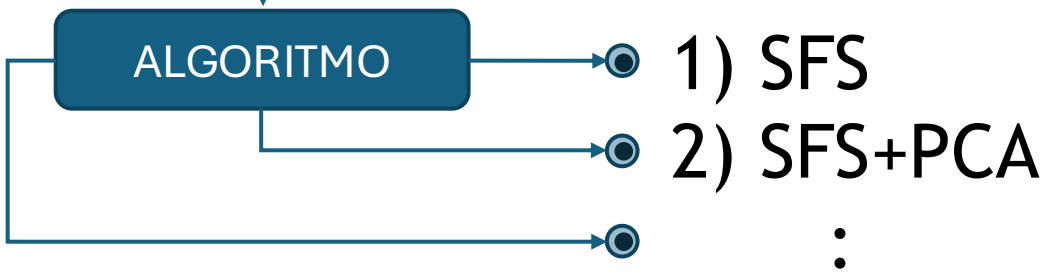
(Xtrain_lbp_gray,ytrain) = extract_features('gray','train','lbp')
(Xtest_lbp_gray,ytrain)  = extract_features('gray','test','lbp')

(Xtrain_lbp_gray,ytrain) = load_features('gray','train','lbp')
(Xtest_lbp_gray,ytrain)  = load_features('gray','test','lbp')
```

CADA GRUPO DE FEATURES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO

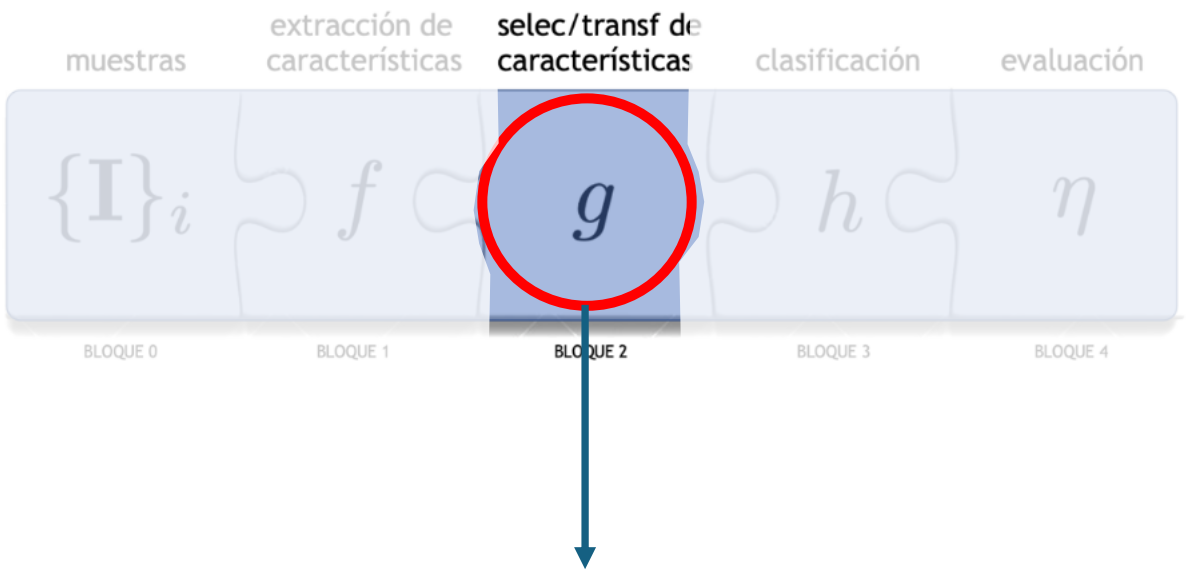

muestras
extracción de características
selec/transf de características
clasificación
evaluación
$\{\mathbf{I}\}_i$
f
g
h
η
BLOQUE 0
BLOQUE 1
BLOQUE 2
BLOQUE 3
BLOQUE 4





SELECCIONAR, GUARDAR, INDEXAR

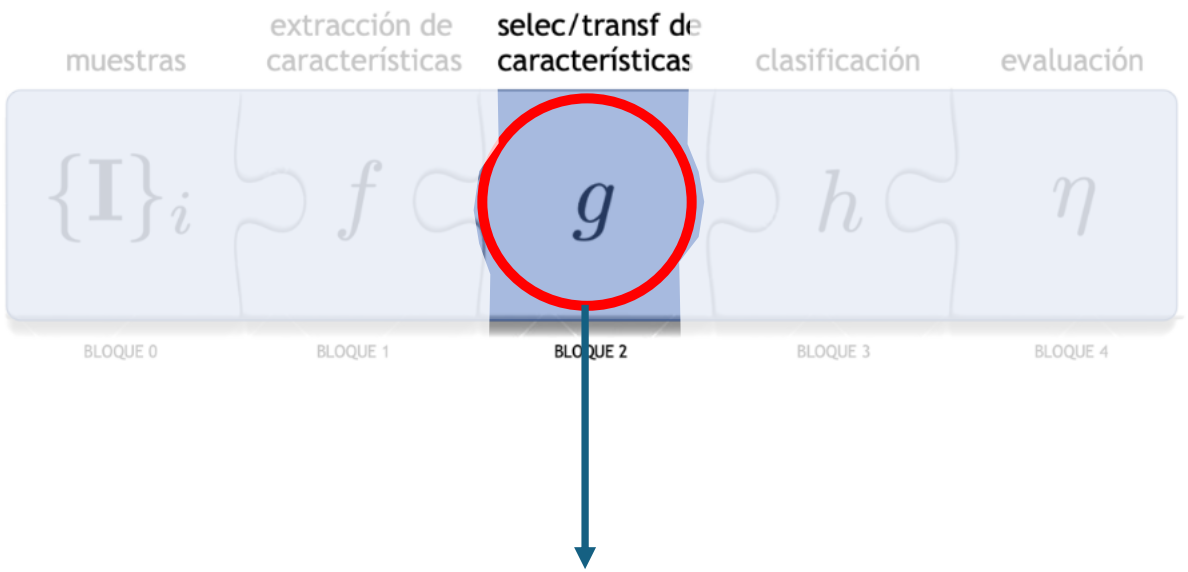
CADA GRUPO DE FEATURES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO




```
Crear funciones como por ejemplo

X1 = np.concatenate((Xtrain_lbp_gray,Xtrain_lbp_red),axis=1)
X2 = np.concatenate((Xtest_lbp_gray ,Xtest_lbp_red),axis=1)
sel = select_features(X1,ytrain,algoritmo=1)
X1_sel = X1[:,sel]
X2_sel = X2[:,sel]
```

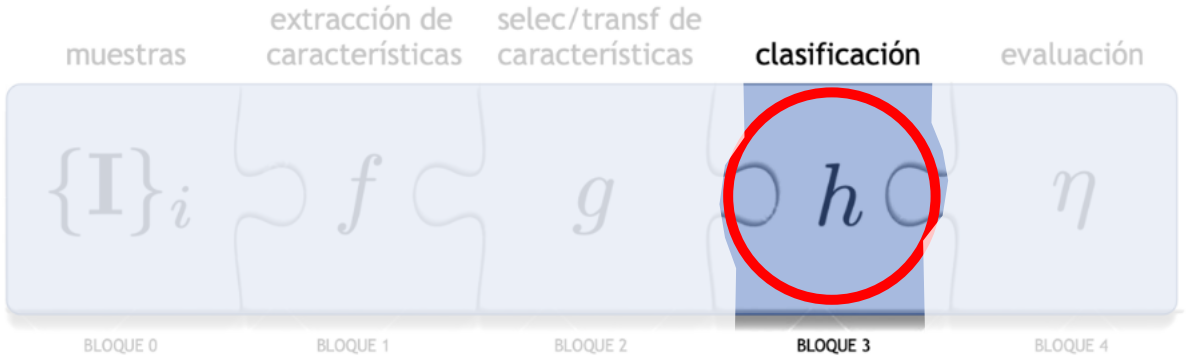
CADA GRUPO DE FEATURES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO



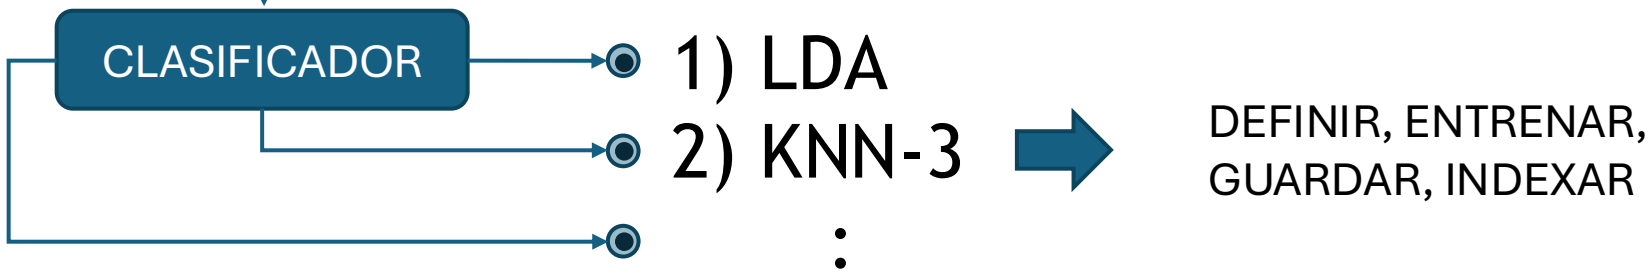

```
Crear funciones como por ejemplo

sel = load_selected_features(algoritmo=1)
X1_sel = X1[:,sel]
X2_sel = X2[:,sel]
```

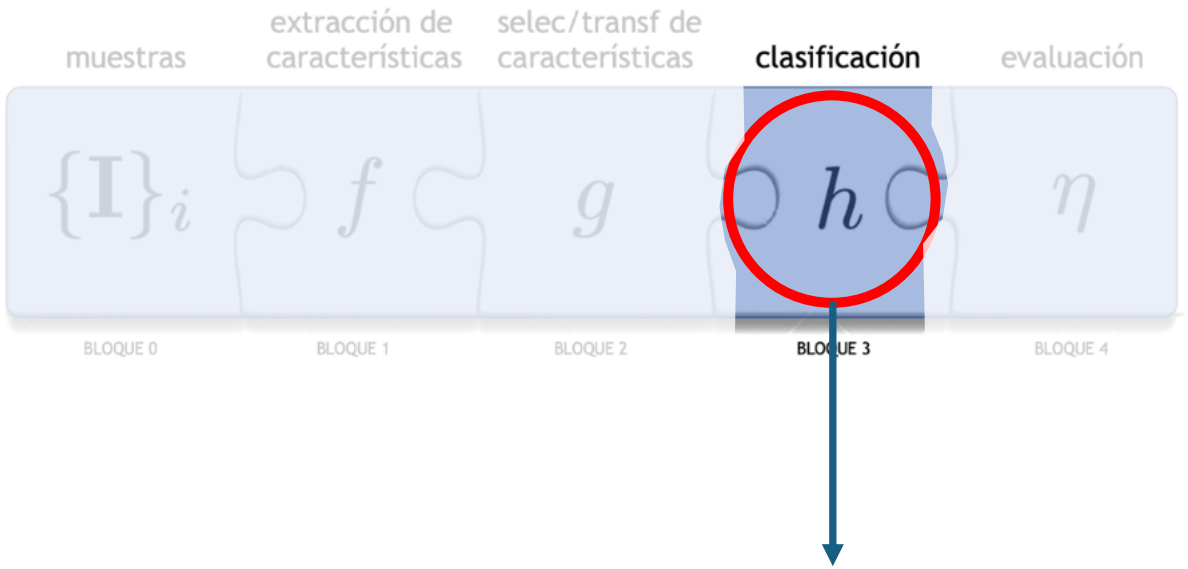
CADA GRUPO DE FEATURES GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO


muestras
extracción de características
selec/transf de características
clasificación
evaluación
$\{\mathbf{I}\}_i$
f
g
h
η
BLOQUE 0
BLOQUE 1
BLOQUE 2
BLOQUE 3
BLOQUE 4





CADA CLASIFICADOR GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO




```
Crear funciones como por ejemplo

clf = load_classifier(1)
clf.fit(X1_sel,ytrain)
ypred = clf.predict(X2,sel)
```

```
Crear funciones como por ejemplo

clf = load_trained_classifier(1)

ypred = clf.predict(X2,sel)
```

➡ CADA CLASIFICADOR GUARDADO EN LA NUBE, INDEXADO, DE FÁCIL ACCESO



DEFINIR

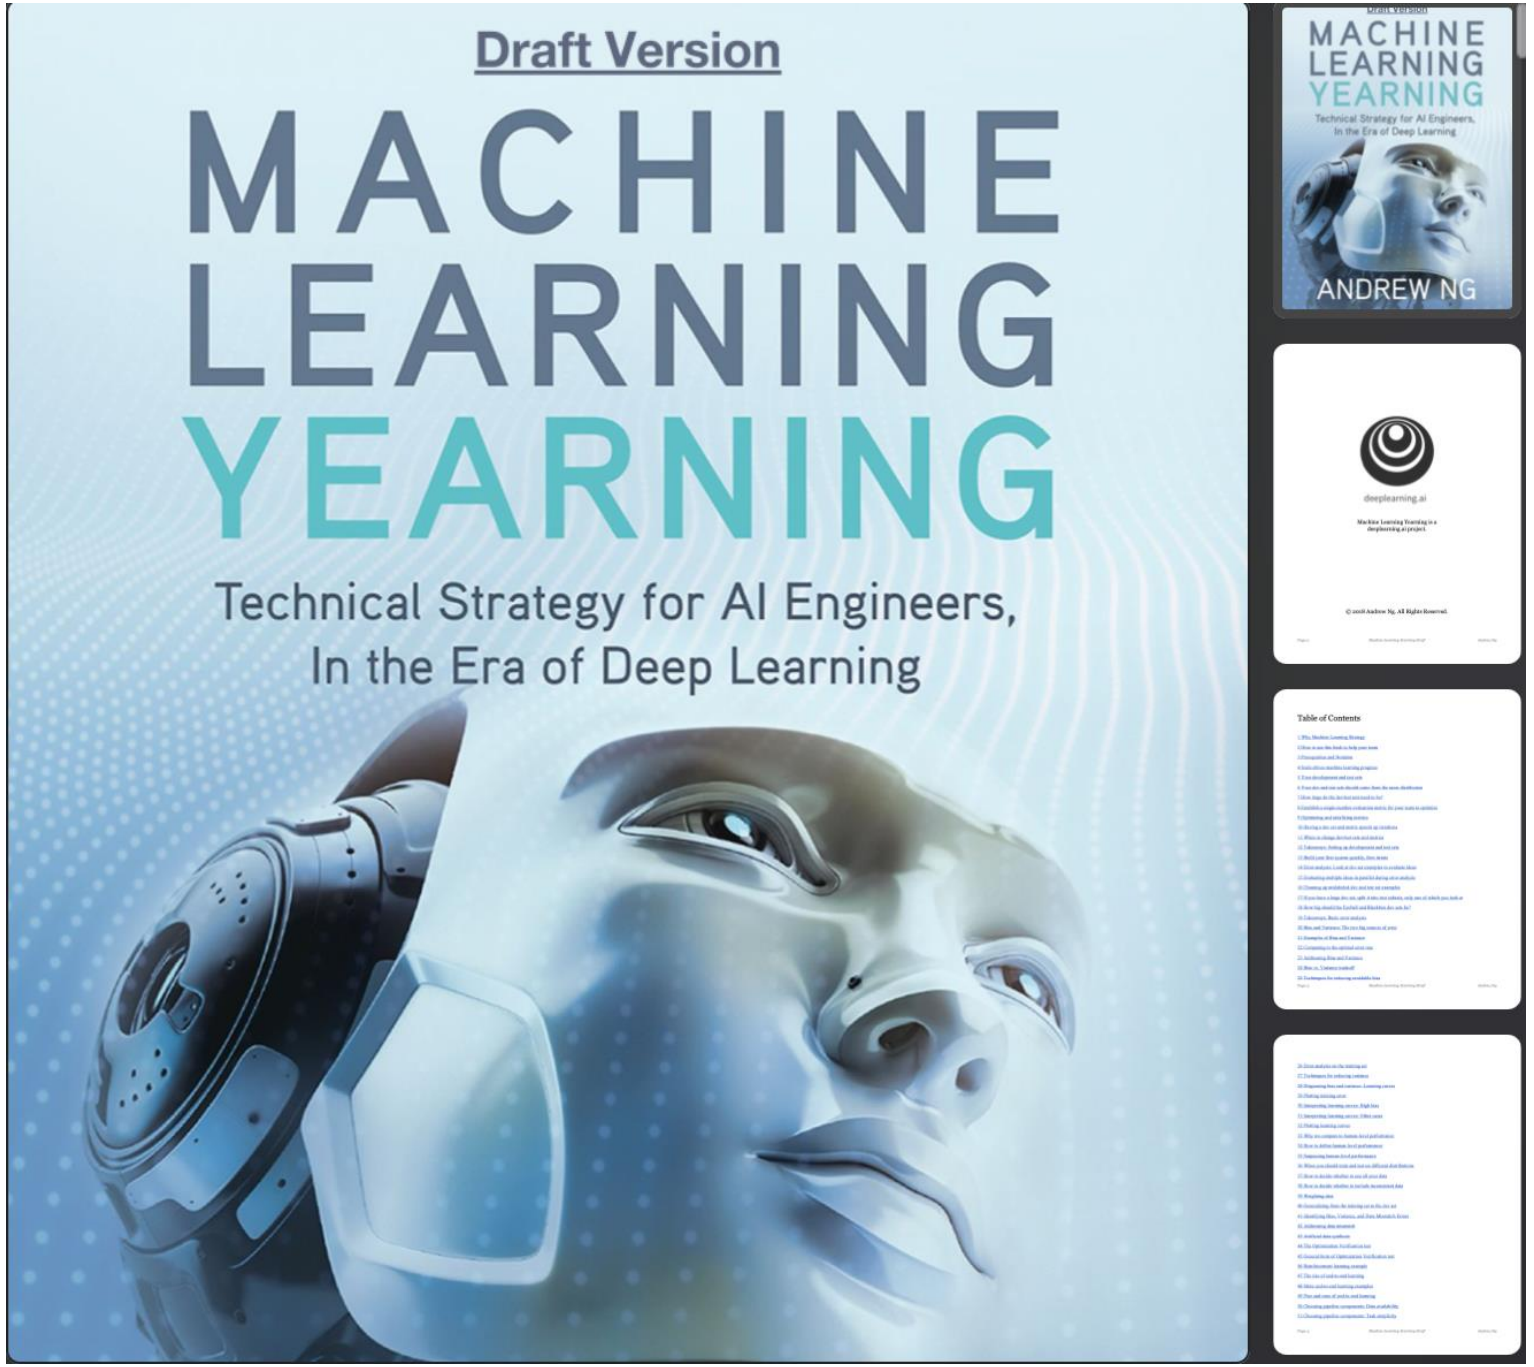
1) holdout
2) crossval
3) reports

DEFINIR, GUARDAR

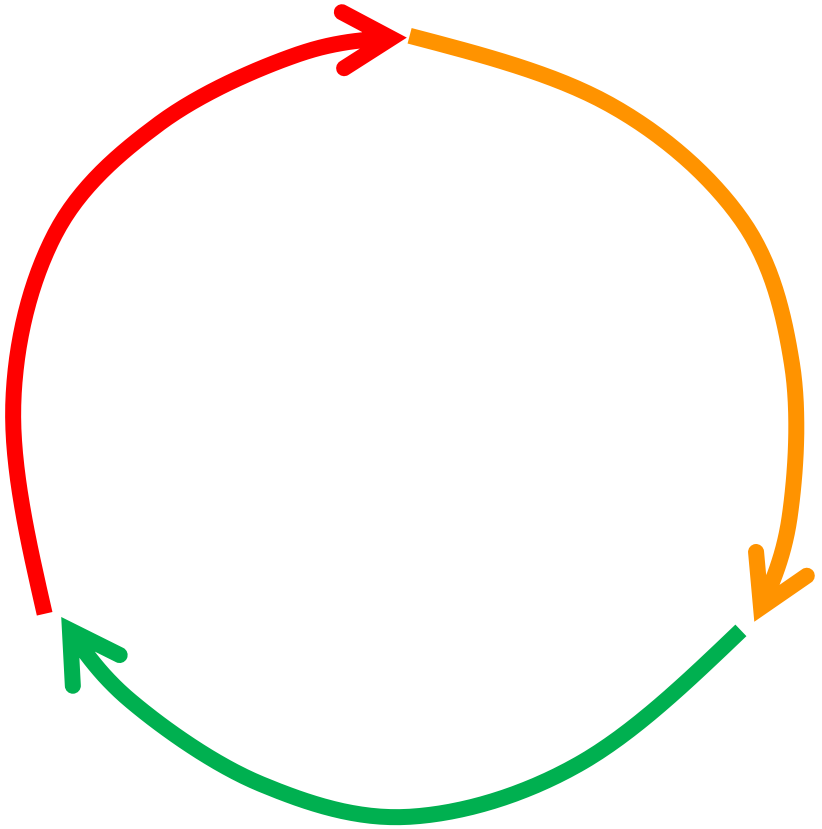
Para tener claridad de qué modelo evaluados con sus métricas de desempeño

Implementación y Pruebas

(Metodología de Andrew Ng)


Draft Version
MACHINE LEARNING YEARNING
Technical Strategy for AI Engineers, In the Era of Deep Learning
ANDREW NG
deeplearning.ai
Table of Contents

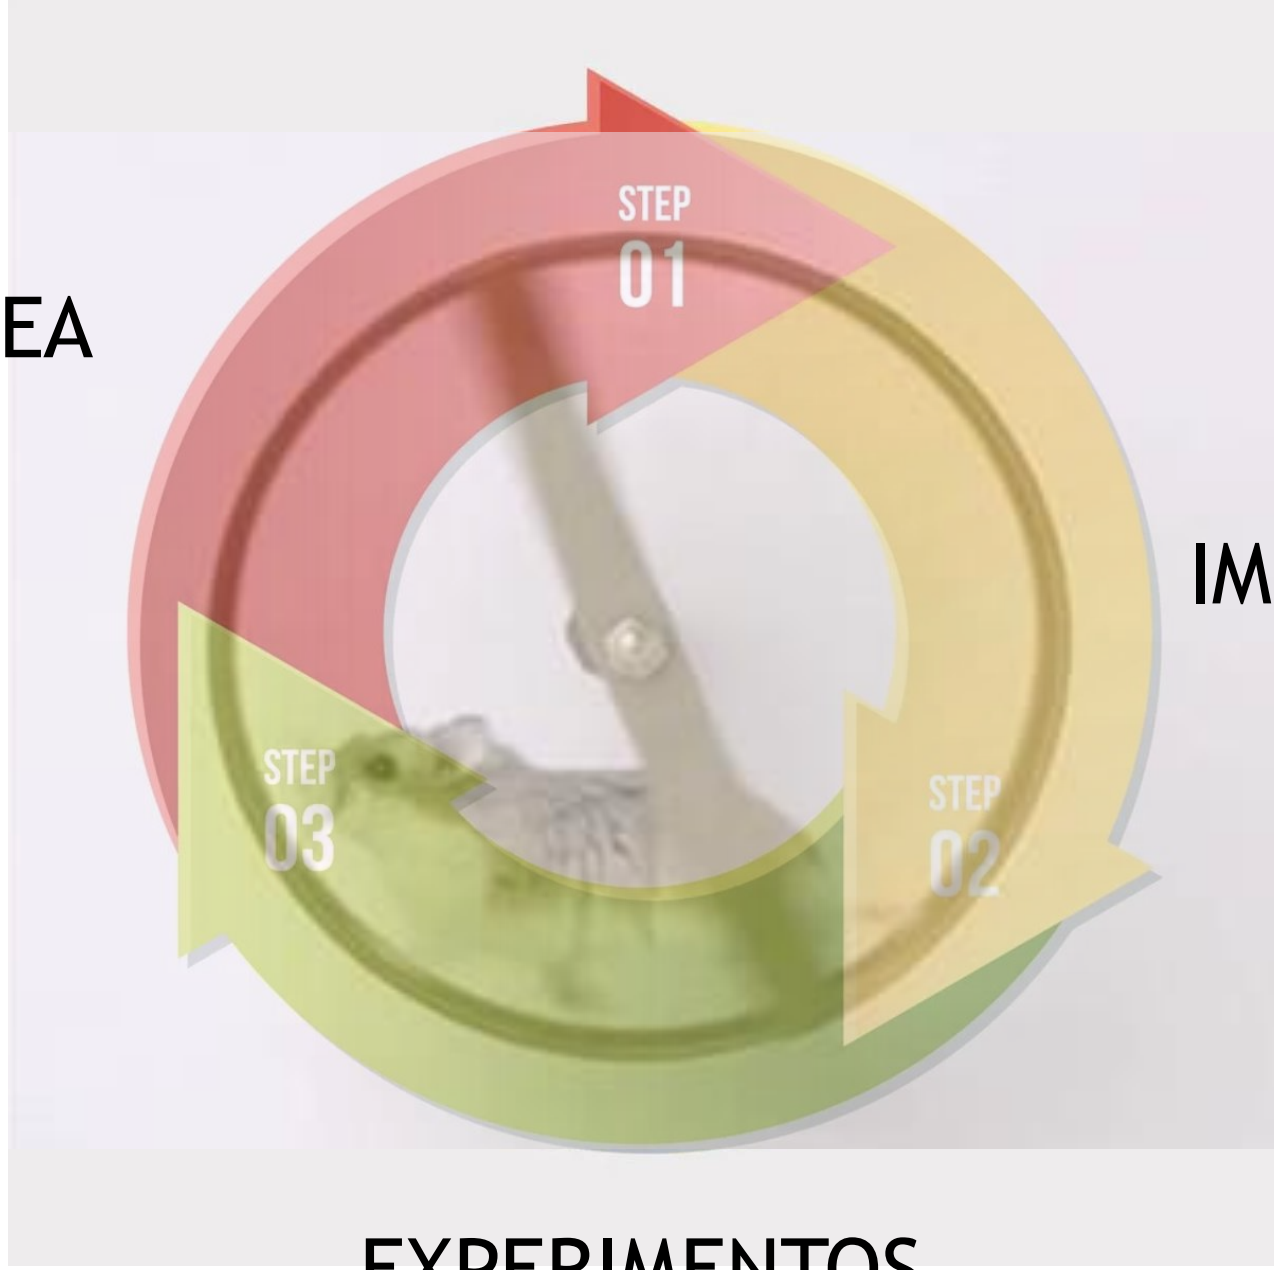
IDEA



IMPLEMENTACIÓN

EXPERIMENTOS

IDEA



IMPLEMENTACIÓN

EXPERIMENTOS

Consejos:

- Como en esta metodología hay que dar muchas vueltas, hacer todo lo posible para que las primeras vueltas sean rápidas, esto quiere decir que los primeros experimentos (con los primeros resultados, aunque sean malos) se deben conseguir en las primeras horas o días.
- Empezar con pocos datos, para tener entrenamientos rápidos.
- Dejar los entrenamiento y pruebas que demanden más tiempo cuando se tenga completa seguridad de que la implementación está haciendo exactamente lo que queremos que haga.